



中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生

数学建模竞赛

学 校

参赛队号

1.

队员姓名 2.

3.

中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

**题目：复杂场景下多模态情感预测的
时序建模与可解释融合**

摘要

针对多模态情感预测中的时间对应、局部信息缺失及决策解释，建立有效观测约束下的特征组织、联合预测与可加解释方法。实验使用题目附件，三项任务分别输出全量特征、专项预测和局部证据。

问题一按实际音视频时钟提取上下文化文本、声学量、画面与人脸形变特征，分离物理时间支持、逐维有效性和内容对应。利用无提示语音识别与双上下文音素对齐生成候选，以词序和时间双重约束求解词组选择。100 条样本全部保留；1932 个原词中 1397 个获得词级候选，50 个词组另覆盖 71 个词，总候选覆盖率 75.98%。固定证据下，动态规划保持覆盖、减少 3 个词组并消除 2 对不兼容关系。同环境重建的 3100 个特征与索引数组一致。

问题二采用编码前缺失屏蔽、观测掩码汇总和可用比例输入，联合优化极性分类与强度回归。通过视频分组三折选择逆频率类别权重，在验证集三种子确认中，Macro-F1 均值由 0.5959 提高到 0.6163，中性 F1 由 0.3871 提高到 0.4808，Accuracy 由 0.6369 降至 0.6277，MAE 为 0.5790。连续缺失实验显示，文本缺失影响更大，缺失位置与片段形状也改变结果。给出附件三全部 30 条预测。

问题三用单模态项、成对交互和残差方差驱动的缩放构造融合模型，将分类间隔与回归预激活精确分解到模态和局部位置。验证集 Accuracy 为 65.11%、Macro-F1 为 0.6323、MAE 为 0.5397、Pearson 为 0.6993。验证、测试及专项样本共 1475 条的分类分解最大绝对误差为 1.52×10^{-6} 。附件四 20 条均输出预测、贡献及关键位置，18 条取得可回看的关键时间范围。

上述方法分别以候选覆盖与稳定性、预测误差、分解一致性评价时间组织、情感预测和模型解释，保留输入缺失及定位支持不足的明确状态。

关键词：多模态情感预测；多粒度时序对应；局部模态缺失；类别平衡；可加解释

1 任务分析与总体思路

情感信息分布在语言语境、声音韵律与视觉表现中。三类观测具有不同采样尺度，局部缺失和内容不一致又使简单拼接难以同时满足预测与解释要求。本文依据三项任务，分别建立原始素材的时间组织方法、局部缺失下的预测模型，以及具有局部贡献分解的融合模型。

问题一的关键在于保留观测并建立粒度和证据状态有区分的对应关系。原始音视频时钟提供物理联系，语音识别与声学边界提供文字对应候选，弱读连读情况下使用词组范围保留整体支持。特征输出同时包含真实长度、位置与有效性，供后续按样本或时间读取。

问题二研究给定特征中局部连续区间不可用时的预测行为。缺失在编码前施加，模型只汇总可见信息，并将可用比例送入融合层。类别平衡以改善三类性能分布为目标；模型效果通过缺失模态、比例、位置及形状的配对实验说明。

问题三将解释结构直接写入预测模型：单模态项和成对项构成输出，可靠性系数调整当前样本的融合尺度。贡献分数核算分类间隔或回归预激活，关键项保留原特征位置；复用问题一的定位方法关联媒体候选范围。




图 1.1 三项任务的实际输入与输出。虚线表示定位方法复用。

问题二、三使用题目提供的预计算特征训练，问题一新提取的矩阵作为独立特征结果保存。三个部分共享观测有效性与位置记录的处理思想，具体特征维度、标准化方法和预测模型分别定义。全文结果整理及构建代码使用 OpenAI Codex (GPT-6) 辅助；使用日期为 2026 年 9 月 26 日，版本发布日期未在本次环境提供。数值来自本地实验记录，公式与处理逻辑按相应实现核对。

2 数据组织与评价约定

2.1 数据与输入版本

全部任务使用题目附件。附件一包含 100 条原始视频及文本、情感标签，样本由视频标识和片段标识联合确定。附件二提供情感强度标签与预计算特征；问题二、三统一采用 aligned_50 版本，附件三、四分别用于两问的无标签专项推理。

表 2.1 数据划分与用途

集合	样本数	负向	中性	正向	用途
附件二训练	3395	967	758	1670	参数拟合
附件二验证	728	206	184	338	模型比较与误差分析
附件二测试	727	207	158	362	描述性评价
附件三	30	—	—	—	问题二专项预测
附件四	20	—	—	—	问题三预测与解释

每条预计算样本最多 50 个对齐位置，声学维度 74、视觉维度 35；文本包含 768 维连续表示及三行 BERT 输入记录。两个预测模型均使用词元编号进入 BERT，训练、验证与专项推理保持接口一致。对齐位置表示附件的共同序列索引，精确物理时间通过原始媒体另行记录。

标签 $y \in [-3, 3]$ ，负值、零值、正值分别对应负向、中性、正向，类别编码 $c \in \{0, 1, 2\}$ 。原始标签和划分保持不变，均值、标准差及类别频率只由相应训练子集估计。

2.2 共用符号与评价量

i 表示样本， j 表示序列位置， $m \in \{T, A, V\}$ 表示文本、语音与视觉。 X^m 为模态特征， o^m 为原观测掩码， v 为有效位置标记， d^m 为额外缺失标记， $\tilde{o}^m = vo^m(1 - d^m)$ 为模型可用位置。问题一另保存人脸事件 F 及逐维有效性；单个合法数值为零时仍保留其观测状态。

预测评价使用 Accuracy、三类等权 Macro-F1、强度 MAE 和 Pearson 相关系数：

$$\text{Acc} = \frac{1}{N} \sum_i \mathbf{1}(\hat{c}_i = c_i), \quad \text{MacroF1} = \frac{1}{3} \sum_{c=0}^2 \frac{2TP_c}{2TP_c + FP_c + FN_c}. \quad (2.1)$$

$$\text{MAE} = \frac{1}{N} \sum_i |\hat{y}_i - y_i|, \quad r = \frac{\sum_i (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum_i (y_i - \bar{y})^2 \sum_i (\hat{y}_i - \bar{\hat{y}})^2}}. \quad (2.2)$$

F1 分母为零时该类别记 0；相关系数分母为零时记未定义。Macro-F1 与 Accuracy 评价离散类别，MAE 与 Pearson 评价连续强度。时间候选覆盖率以原词总数为分母，解释分解误差比较贡献之和与当前模型读出，分别在相应章节报告。

3 问题一：三模态特征与多粒度时序对应

3.1 建模目标与数据约束

对附件提供的 100 条视频，令样本标识为 $s = (\text{video_id}, \text{clip_id})$ ，原文为 R_s ，情感标注为 y_s 。我们建立文本、语音和视觉特征序列及其跨模态关系，保留全部样本、原文和标签。情感标签作为原始样本信息保存，模型采用固定预训练工具与统一参数，全部实验基于赛题附件。

本模型分别记录素材的时间支持、特征维度的有效性及文本与语音的内容对应。输出由原生变长特征、物理时间索引和带状态的文本时间候选组成，各层通过样本编号与位置记录关联。

3.1.1 附件自身的输入核验

文本模态以附件表中的原始 text 为输入，语音和视觉模态分别以附件视频的实际音轨和画面为输入。三者通过样本编号关联，局部内容对应由实际音轨、匹配证据及时间约束共同确定。

处理前对 100 条原视频逐一校验编号、文件摘要与解码结果，读取真实 PCM 样本数和各声道幅值。本批 100 条音轨均可解码且未出现 FFmpeg 警告，其中两条全部声道严格为零；忽略 MP4 编辑列表后仍全零，因此将其标记为声音不可用。其余音轨记录为信号存在，文字对应由后述识别与声学互证方法检验。

3.1.2 输出目标与处理原则

样本输出记为 $\mathcal{O}_s = (\{X_s^m, L_s^m, M_s^m, P_s^m\}_m, \mathcal{G}_s^{time}, \mathcal{G}_s^{text}, R_s, y_s)$ ： X 是原生特征， L 是真实长度， M 是有效性掩码， P 是字符、帧或时间位置； $\mathcal{G}^{time}$ 按附件时钟建立物理关系， $\mathcal{G}^{text}$ 只保存满足证据规则的文本候选边。人脸作为视觉模态下的独立事件流保留。文本时间关系未确定时，原文、声学特征与物理时间索引继续保留。

表 3.1 输出目标与处理原则

数据情形	特征如何保留	时间关系如何建立
文本与实际语音有匹配证据	保留三模态原生序列	按识别与声学互证规则给出词级候选，再按实际支持聚合
全零音轨	保留样本与存储结构，声音可用标记为 false ；文本及可用视觉照常提取	语音词界标记为不可用，声音聚合返回无效掩码
语音存在但内容不对应，或模型无法确认	保留原文及实际声学、画面特征	物理音视频索引仍可使用，文字局部关系按证据保留未确定
弱读、连读、专名或首尾额外语音	完整保留原文和实际声音	用外侧通配与局部互证建立候选，逐词记录证据状态
疑似非英语或译文关系	保留各模态及待核查状态	采用固定英语对齐工具；跨语言对应保留未确定状态
画面有人脸缺失、多人或遮挡	画面特征与人脸事件分别保留	整体画面与人脸检测状态分别记录，发声者身份标记未知

表中情形采用统一处理规则。未确定状态包含数据对应问题和模型识别能力不足，具体原因按匹配证据及信号状态记录。

3.2 原始时钟与处理流程

逐条读取原视频、文本和标签，检查编号唯一性与 SHA256 摘要。使用 FFprobe 取得音视频解码帧的 PTS、time_base 与长度；声音另核对 FFmpeg 实际输出的 PCM 样本数。源音频采样率为 f_s 、起点为 t_0 时，采样点 j 的时间为 $t_0 + j/f_s$ 。视频第 i 帧的显示支持为 $[p_i, p_i + d_i)$ ，物理支持集合为这些区间的并集。有效观测时长按解码后的实际支持计算。

模型用音频在声道均值后重采样为 16kHz；原采样率、声道数、样本数及起点保留。两条全零音轨仍输出完整记录和特征存储结构，但语音可用性为 **false**，不运行文字强制对齐。源文件未修改。流程为：原始清单与时钟审计 → 原生三模态特征 → 文字时间候选与选择性筛选 → 物理支持下的跨模态聚合 → 全量核验与汇总。

容器声明时长与实际解码支持可能不同。例如一条视频声明 7.475 秒，实际 PCM 约 2.820 秒、画面支持约 2.870 秒，时间关系按后两项建立。

3.3 三模态特征定义

3.3.1 文本

固定 DistilBERT[1] 最后一层输出子词向量 $h_k \in \mathbb{R}^{768}$ 。原文词 w_j 保存字符区间 $[l_j, r_j)$ ，其特征为

$$x_j^T = \frac{1}{|B_j|} \sum_{k \in B_j} h_k, \quad B_j = \{k : \text{子词字符区间与 } [l_j, r_j) \text{ 相交}\}. \quad (3.1)$$

原始文本直接输入文本模型；数字口语化、大小写等规范化只服务于语音匹配，并保存其与原词的映射。完整文本经子词映射形成逐词上下文表示，保留情感词、否定和程度修饰所在的语言语境。

3.3.2 声音

16kHz 音频采用 400 点 Hann 窗和 320 点步长，即 25ms 窗口、20ms 步长。令窗口信号为 $a_i[n]$ ，计算 512 点功率谱 $P_i[k]$ ，通过 40 个 HTK Mel 三角滤波器 $H_b[k]$ 得到

$$E_{ib} = \log \max \left(\sum_k P_i[k] H_b[k], 10^{-12} \right), \quad c_i = \text{DCT}_{II}^{\text{ortho}}(E_i)_{0:13}. \quad (3.2)$$

另取对数 RMS、相邻采样符号改变比例 ZCR、基频和周期性，组成 17 维向量。对数 RMS 为 $\log \max(\sqrt{\text{mean}(a_i^2)}, 10^{-12})$ 。音高采用以该帧为中心的完整 1024 点窗口，去均值后归一化自相关，在 50-500Hz 对应滞后范围内寻找峰值；周期性不低于 0.6 时输出 $f_0 = 16000/\text{lag}$ 。窗口不足或能量不足时相应维度无定义；周期性足够低时仅基频无定义。

缺失维度存储零并配 false 掩码，读取以掩码为准。能量、频谱和音高序列描述声音强弱、音色及发声周期变化，为情感分析提供声学线索。

声学特征描述实际音轨，适用于其中的语音、音乐和环境声。特征有效性按数值定义判断，目标文字对应按声学匹配判断；语音活动、语言及说话者身份属于额外识别任务。

3.3.3 视觉

按 0.2 秒目标步长选取实际视频帧，保存真实帧编号和 PTS。画面经 ResNet18[2] ImageNet 标准预处理后，提取全局平均池化的 512 维向量 x_i^V ，表达画面上下文。

MediaPipe FaceLandmarker[3] 为每个检测人脸输出 52 维形变向量 x_e^F 。全图未检出时在四个固定重叠区域检测；框映回原图，以 IoU 不低于 0.5 去重，优先保留非触边、面积较大的候选。每个事件保存原帧行、归一化框、裁剪来源和触边状态。同帧人脸分别保存为局部形变事件，身份及其与说话者的关联标记未知。

3.3.4 特征选择与情感任务的关系

三类特征从语言语境、声音韵律、画面背景与面部动作四个方面组织情感相关信息。变长序列保留局部变化，时间对应支持同一片段内的跨模态比较。

表 3.2 特征选择与情感任务的关系

特征	所保留的情感相关信息	本问输出的含义
上下文文化文本向量	词语在原句中的语义和上下文，例如否定与程度修饰所在的语境	逐词上下文语义表示
MFCC、能量、ZCR、基频与周期性	频谱、强弱和发声周期随时间的变化	可计算的声学量；音乐和环境声也可能产生有效值
全局画面向量	场景与可见内容背景	整体场景与可见内容表示
人脸形变事件	检出人脸的局部几何动作	逐个人脸的形变表示，附检测状态与位置

这组特征兼顾上下文信息、可解释声学量和面部动作线索。画面以约 5 帧/秒采样，面向片段级视觉变化。评价围绕特征定义与计算、实际可用性、时间对应和复现一致性展开，分别给出全量统计、受控实验及真实样本展示。

3.4 文本时间候选与不确定性

3.4.1 基础选择性对应

把词 j 的关系状态记为 $c_{sj} \in \{\text{candidate}, \text{unresolved}\}$ 。前者表示通过下述证据规则，后者表示当前证据不足。只有 $c_{sj} = \text{candidate}$ 时才建立候选词区间到其他模态的边。人工内容判断用于离线评价，候选由统一规则自动生成。

采用固定 Wav2Vec2 CTC[4] 模型获得逐帧字符分数。一条分支按给定原文强制对齐，允许两侧额外语音由外侧通配符吸收，但不跳过原文内部字符。路径最大化 $\sum_t g_t(\pi_t)$ ，去重去 blank 后须符合外侧通配符加原文字符序列的约束。普通符号使用模型 log 分数，通配符得分为 0，故路径分数不是正确率。通过两个仅允许通配符的虚拟端帧处理空外侧，输出时丢弃虚拟帧。

模型总步长 S 、感受野 R 由各卷积层递推，输出帧 k 的中心为 $t_0 + (kS + (R - 1)/2)/16000$ 。相邻中心中点形成单元，首尾裁到模型音频范围；强制对齐词区间由首末字符覆盖的单元确定。CTC 响应峰不天然覆盖完整发音，因此区间首先是候选。

另一条分支自由识别音频，随后将整个原文与识别序列进行半全局编辑匹配。设代价单位为 1000，插入删除为 1000；相同词替换代价为 0；两词长度均至少 4 且归一化字符编辑距离不超过 0.25 时，替换代价为距离乘 1000 后取整，其余为 1000。动态规划满足

$$D(i, j) = \min\{D(i - 1, j) + 1000, D(i, j - 1) + 1000, D(i - 1, j - 1) + c_{ij}\}, \quad (3.3)$$

其中 $D(0, j) = 0, D(i, 0) = 1000i$ ，终点取 $\min_j D(n, j)$ 。通过前向和后向代价枚举所有最优路径上的对应关系，而非任意选择一条最优路径。

自动词候选要求：样本至少含两个不同的信息性精确锚词，信息性词类型覆盖不低于 0.5；该词各规范化部分在所有最优路径中均唯一且连续地精确对应；识别区间与强制对齐区间的最大端点差不超过 0.2 秒。信息性词为长度至少 4 且不在配置中固定功能词表的词。近似匹配参与路径搜索，但不直接获得词级输出资格。这些固定工程规则用于统一筛选候选。

满足规则时输出识别词区间，否则保留原词、特征和未确定原因。最优路径唯一性针对本次识别序列；两条 CTC 分支的端点比较衡量同一模型内部的一致性。专名、弱读及识别拼写差异造成的匹配歧义继续保留，并由后续局部发音对齐补充检验。

在上述基础门控之外，局部互证策略增加局部上下文互证。将原文与识别结果中连

续、唯一精确对应且满足原边界一致性要求的词组成最大局部片段，每段至少包含两个不同信息性锚词。设片段 B_i 的锚词集合为 A_i ，对于整句门控未通过的样本，仅当存在另一个分离片段 B_j 满足 $A_i \cap A_j = \emptyset$ 时，恢复 B_i 的自动候选。一次偶然短语相同或重复使用同一对锚词不足以恢复。原有候选不修改；恢复词单独标为 `local_coherent_candidate`。互证范围为同一识别结果中的分离片段，确认粒度保持局部。

3.4.2 无提示识别与局部发音对齐

增强分支使用固定 **Whisper large-v3**[5] 模型识别完整音轨，采用 **English**、**beam size 5**、**temperature 0**、关闭前文继承和 **VAD** 裁剪，输入中不提供原文提示或热词。识别结果按与原文相同的规则归一化，通过全最优编辑路径查找位置唯一、词序连续的精确匹配。局部片段至少含两个不同的信息性锚词；整句支持不足时，沿用分离片段互证条件。

对每个受支持片段，分别保留前后 0.5 秒与 1 秒上下文，用固定 **MFA**[6] 英文声学模型、发音词典及 **G2P** 进行原文音素对齐。发音候选由通用词典和 **G2P** 产生，原始文本与词典按统一规则使用。令两个上下文得到的词区间为 $I_j^{(0.5)}, I_j^{(1.0)}$ ，**Whisper** 区间为 J_j ，定义端点差 $d(I, J) = \max(|I_{start} - J_{start}|, |I_{end} - J_{end}|)$ 。新词级候选要求区间有效，且

$$d(I_j^{(0.5)}, I_j^{(1.0)}) \leq 0.2s, \quad d(I_j^{(0.5)}, J_j) \leq 0.2s. \quad (3.4)$$

该容差继承基础配置，用于模型间一致性检查。已有候选与受支持的新位置冲突时，保存两个区间并将关系标记为未确定；新增候选与已接受相邻词发生时间交叉时拒绝新增。

3.4.3 证据约束下的词组选择

词级冲突处理完成后，对连续 2-8 个原词生成词组候选。候选须满足文字身份唯一、词序连续、音素路径有效、组外端点一致，并与最终接受的词级关系兼容。内部存在跨模型位置冲突的词组不进入候选集。词组仅保存整体范围与原词索引，内部词时间保持未确定。

令最终无词级时间的词集合为 U ，合格词组 p 的原词范围为 $[l_p, r_p]$ 、声音范围为 $[a_p, b_p]$ 。两个词组可顺序共存，当且仅当

$$p \prec q \iff r_p < l_q \text{ 且 } b_p \leq a_q. \quad (3.5)$$

实现使用 10^{-7} 秒数值容差。由此，所选词组在原词索引和声音时间上均不重叠。为兼顾覆盖和关系粒度，在合格候选中按字典序最大化

$$\left(\sum_{p \in \mathcal{P}} |U \cap [l_p, r_p]|, -\sum_{p \in \mathcal{P}} (r_p - l_p + 1), -|\mathcal{P}| \right). \quad (3.6)$$

第一项最大化新增未定词覆盖；覆盖相同时，第二项优先更短的总词跨度，再由第三项减少词组数量。该目标只在已经通过内容与声学检查的候选中进行选择。

按右侧原词位置排序，记每个词组的上述三维权重为 $w(p)$ ，以 p 结尾的最优序列满足

$$F(p) = w(p) + \max_{q \prec p}^{lex} \{F(q), (0, 0, 0)\}. \quad (3.7)$$

取所有终点与空序列中的字典序最大值并回溯，得到全局最优的可共存词组集合。任一有效序列的前缀仍为有效序列，且权重可加，因此上述动态规划穷尽了最优前驱；候选数为 K 时，得分递推进行 $O(K^2)$ 次兼容性检查。该最优性针对给定候选集合及上述覆盖目标。

先完成词级决策，再选择词组，可以在单词定位因邻接冲突而被拒绝时保留其合格的组级证据；双重顺序约束则避免多个重叠词组重复描述同一片段。

3.5 跨模态支持约束与逐维聚合

目标区间为 I 、特征行代表单元为 J_i 、真实素材支持集合为 S ，定义交叠权重

$$w_i(I) = |I \cap J_i \cap S|. \quad (3.8)$$

画面代表单元采用相邻采样帧 PTS 的中点分割；在单元内使用邻近采样画面，是明确的离散近似。视频空缺不产生观测，重叠源帧以并集计时。文本候选区间和纯物理查询都可使用该算子，但后者不自动建立文本对应。

音频同样与原始 PCM 的实际支持相交，不能把重采样后按整数样本数构成的末端直接当作原素材末端。本批 99 条的重采样单元存在不足一个 16kHz 采样间隔的末端超出，最大约 61.08 微秒；精确裁切使 97 条物理索引合计减少约 2.86 毫秒的虚增观测。原生特征、文字候选及其决策均不变。该修正统一了聚合区间与原始素材的时间定义。

对第 d 维有效掩码 m_{id} 和模态可用标记 u ，定义

$$D_d(I) = \sum_i w_i(I) m_{id} u, \quad \bar{x}_d(I) = \frac{\sum_i w_i(I) m_{id} u x_{id}}{D_d(I)}. \quad (3.9)$$

分母为 0 时返回零及 false 掩码。每维独立分母避免缺失音高被填零后稀释。另输出 $\sum_i w_i(I)/|I|$ 作为物理覆盖比例。人脸按独立事件列表返回。

3.6 文件组织与全量结果

每条样本以 NPZ 保存原生矩阵与掩码，以 JSON 保存身份、原文、字符映射、源摘要及处理信息。标准化处理包括固定采样率、模型规定的输入预处理，以及统一的特征、时间和掩码组织；声学量按特征定义的量纲保存。文本 768 维、声学 17 维、画面 512 维、人脸 52 维；序列变长存储。批处理时按模态右补零，统一返回真实长度、序列掩码、逐维掩码和样本可用性。对样本 s 、行 i 、维度 d ，实际使用掩码为 $B_{sid} = \mathbf{1}(i < L_s) m_{sid} u_s$ ，其中 u_s 为该模态的样本级可用标记。Dataset.batch(ids, modality) 自动将不可用位置置零并返回这些掩码：全零音轨仍保留真实长度和序列位置，但所有声学维度的使用掩码为 false；正常输入的数值零不会被判为缺失。此操作只构造批量视图，不改变原生特征文件。

物理索引按画面代表单元组织，保存声音稀疏行索引及交叠秒数、逐维聚合、观测时长和人脸事件映射。全 100 条共 4030 个节点、42667 条声音关联，全部 1932 个原词及原始标签保留。基础策略输出 1342 个词级候选。增强策略输出 1397 个词级候选，50 个词组候选额外覆盖 71 个无词级时间的词；464 个词保持完全未确定。词级覆盖率为 72.31%，词级或词组级覆盖率为 75.98%，二者均以全部 1932 词为分母。

使用 multigranular_reader.Dataset(root).sample(sid) 读取结果；sample.word(i)、sample.phrase(k) 和 sample.window(a,b) 分别查询原词、词组及物理时间区间，Dataset.batch(ids, modality) 构造掩码批量。读取器核对来源并复算关系决策。正文全量表逐条给出有效时长、序列形状和对应粒度。

3.7 实验结果与误差来源

3.7.1 连续语音与多粒度增强结果

全部 100 条采用统一无提示识别。原 CTC 识别与原文的唯一精确词匹配数为 1390，Whisper 为 1624；该指标衡量文字一致性。生成阶段未读取人工转写、人工时间、复核备注或情感标签。筛选得到 118 个局部片段，形成 236 个 MFA 裁剪任务，

其中 117 个片段有两种不同裁剪，1 个片段的裁剪因音轨边界而重合。

表 3.3 连续语音与多粒度增强结果

输出	基础策略	增强策略
词级候选	1342 (69.46%)	1397 (72.31%)
仅由词组关系覆盖的词	0	71
词级或词组级覆盖的词	1342 (69.46%)	1468 (75.98%)
完全未确定的词	590	464

增强分支提出 80 个新词级候选，16 个因与相邻已接受区间冲突而被拒绝，保留 64 个；9 个原候选因跨模型位置冲突转为未确定，净增加 55 个词级候选。50 个词组候选另外覆盖 71 个无词级时间的词，统计按原词去重。

仅替换识别序列并沿用原 CTC 边界比较时，候选数为 685，反映不同识别器时间定义的差异。局部音素对齐重新估计边界，再按词级或词组级保留支持范围。在 9396 组跨视频音轨一原文错配控制中，通过文字筛选的片段提议为 0；该控制参与方法开发，用于检验构造错配下的筛选行为。

3.7.2 词组选择的固定证据对照

固定 100 条识别输出、236 个局部对齐任务、声学阈值及全部词级决策，只改变词组选择步骤：

表 3.4 词组选择的固定证据对照

选择方式	词级候选	仅词组覆盖词数	词组数	词组间不兼容对数
词级提议阶段筛选、短组优先	1397	56	38	2
最终词级决策后筛选、短组优先	1397	71	53	2
最终词级决策后筛选、双顺序动态规划	1397	71	50	0

延后筛选在 12 条样本中恢复 15 个词的词组级覆盖，原有覆盖均保留；动态规划在相同覆盖下减少 3 个词组，并消除词组间的索引重叠或时间交叉。最终覆盖为 1468/1932 (75.98%)，其中 1397 个词具有词级候选，71 个词仅具有词组关系，464 个词完全未确定。全量词级状态与时间逐项不变。

对全部 100 条倒置候选输入顺序，输出保持一致；移除第二上下文或将音素移至音轨外时，均无新增关系。100 组固定随机种子的合成候选集合中，动态规划与穷举的目标值全部一致。

3.7.3 特征可用性与未确定状态

全部 38776 行声学特征中，前 15 维各有 38190 行可用，基频 16492 行可用，周期性 37988 行可用。4030 个视觉采样帧中，327 帧未检出人脸、3636 帧检出一张、67 帧检出多张，共 3789 个人脸事件，其中 23 个带裁剪边缘标记。逐维掩码保留这些可用性差异。

464 个完全未确定词的互斥状态如下。状态描述所用模型与规则取得的证据；除全零音轨外，识别或边界支持不足仍可能来自连读、弱读、专名及内容差异。

表 3.5 特征可用性与未确定状态

状态	词数 处理
无语音信号	24 声音使用掩码关闭
无信息性锚点	216 保留原文与原生观测
整体支持不足	102 保留局部证据记录
未匹配或位置歧义	96 保留待定位置
仅近似文字对应	16 保留近似匹配证据
跨模型时间冲突	9 分别保存冲突候选
边界不稳定	1 保留边界差异记录

补充发音竞争实验在 81 条样本中产生 393 个片段；上下文发音分支通过 28 个，其中 22 个已有覆盖、5 个涉及时间不兼容或既有冲突，剩余 1 个词组涉及 3 个潜在新增词。其结果单独保存，正式关系统计使用上表及 1397 个词级、50 个词组候选。

3.7.4 基础策略受控稳定性与声学量校核

固定基础策略与参数，对全部 100 条分别执行原输入、波形幅度减半、16kHz 波形前置恰好 1 秒静音，共 300 次完整候选生成。它们不修改原附件或正式结果，也不使用人工词界。原输入条件首先逐词复现正式候选，校验实验实现与实际处理一致。

设原候选集合为 A ，变换后集合为 A' ，已知平移为 δ ，报告保留比例 $|A \cap A'|/|A|$ 及共同候选的端点残差

$$e_j = \max(|a'_j - \delta - a_j|, |b'_j - \delta - b_j|), \quad j \in A \cap A'. \quad (3.10)$$

同时报告候选保留、丢失与新增数量。

表 3.6 基础策略受控稳定性与声学量校核

条件	候选词数	保留原候选	丢失	新增	端点残差中位数/95 分位
原输入	1342	1342	0	0	0/0 毫秒
幅度减半	1342	1342	0	0	0/0 毫秒
前置 1 秒静音并扣除平移	1343	1325	17	18	0/20 毫秒

幅度减半时全部候选及端点不变。前置静音后保留 98.73% 的原候选，共同候选的最大端点残差为 20 毫秒，新增静音内部未出现完整候选区间；但 17 个候选丢失、18 个新增，表明识别上下文变化会影响候选集合，平移稳定性具有条件性。这里的 20 毫秒是相对原自动输出的端点残差。

另用 80、120、200、300、400Hz 解析正弦校核，每种取得 97 个有效基频帧，音高误差 95 分位分别为 17.40、4.33、0、10.85、0 音分。幅度减半时对数 RMS 变化与 $\ln(0.5)$ 一致。上述检验分别验证输出稳定性及声学量的数值定义。

3.7.5 内容评价与指标定义

内容开发评价包含 6 条完整对应样本，其 142 词的基础局部互证候选为 100 个；另 6 条完整音轨被复核为不对应，共 57 词，策略均无候选输出。这些样本用于方法开发，统计描述已核查案例的行为。候选覆盖率以全部原词为分母，表示输出可用比例；识别正确率和词界误差需要独立转写与时间真值。本文分别报告候选覆盖、受控稳定性、声学量误差与重建一致性。

3.7.6 多粒度策略的真实三模态实例

典型样本按固定规则选择：在基础策略全部词均有候选的样本中，取源文件 SHA256 字典序最小的一条。该选择只读取自动结果和源摘要。样本为-UacrmKiT n4\$_\$10，原文为“Because, if they are not in any way held accountable for reading the material they won't do it.”。18 个原词候选的外包范围为 0.522-6.662 秒，包含词间停顿。

图中展示 18×768 文本特征、 307×17 声学行、 31×512 画面行及原始视频帧。缺失维度显示为灰色，显示缩放保留原始特征数值。




图 3.1 自动选择样本的真实三模态实例

原帧编号为 19、108、199，PTS 分别为 0.633、3.600、6.633 秒。音频区间按候选词界组织，画面按实际时间展示同期场景。物理支持运算排除约 4.2088 秒源视频空缺；对 2759 个有效音高的节点，按逐维有效时长归一化，避免缺失音高填零对聚合值的稀释。

物理支持运算排除了约 4.2088 秒源视频空缺；2759 个有效音高的节点中，按总时间平均填零音高会压低数值，逐维有效时长归一化避免该稀释。该实验验证物理支持与逐维归一化的实际作用。

3.8 参数配置与重建流程

表 3.7 参数配置与重建流程

环节	工具及固定配置
基础环境	Python 3.10; FFmpeg/FFprobe 4.4.2; PyTorch/torchaudio 2.6.0 CPU; torchvision 0.21.0; transformers 4.48.3; MediaPipe 0.10.21
基础推理	distilbert-base-uncased; facebook/wav2vec2-base-960h; ResNet18 ImageNet1K_V1; 线程 2、种子 0、推理模式
独立识别	faster-whisper 1.2.1; CTranslate2 4.8.2; large-v3; RTX 4060、int8_float16; 英语、beam 5、temperature 0、关闭 前文条件与 VAD
音素对齐	MFA 3.3.9; english_mfa v3.0.0 声学模型与词典; english_us_mfa v3.0.0 G2P; 16kHz、beam 10、retry 40、 dither 0、关闭说话者适配
局部边界	上下文扩展 0.5 秒及 1 秒; 两种上下文与独立识别的端点一致性 门槛 0.2 秒; 词组长度 2—8 词

运行 `scripts/rebuild_core.py`, 传入原始附件目录、固定模型缓存和新输出目录, 依次生成素材清单、原生特征、基础关系及物理索引。再由 `scripts/rebuild_multigranular.py` 从原始音轨重做独立识别、裁剪与音素对齐, 生成最终词级及词组级关系。模型来源、固定版本与摘要由模型清单记录; NPZ 保存数值, JSON 保存位置与状态。

同一系统和硬件上, 在新安装的 Python 环境中重建全部 100 条, 1900 个原生数组和 1200 个物理索引数组的类型、形状、数值一致。增强分支在新目录重复生成 100 条识别输出、236 个对齐任务及最终关系, 结果一致。该实验验证固定环境、权重和参数下的计算复现。

3.9 全部 100 条特征与时序结果

T、A、V、F 依次表示文本、声音、画面、人脸事件, 特征维度分别为 768、17、512、52。表中列出各序列长度, 乘相应维度即为完整矩阵形状。A/V 时长为实际 PCM 与源帧支持并集的秒数, 保留三位小数; 文本按词和字符区间定位, 人脸按所属帧定位。W/P/U 分别为词级候选数、仅词组覆盖词数、完全未确定词数, 逐行之和等于 T 长度。星号标记全零音轨, 其物理时长保留而声音使用掩码为 `false`; 其他声音轨迹仍采用逐维掩码。

表 3.8 全部 100 条特征与时序结果

样本标识	A 秒	V 秒	T/A/V/F 长度	W/P/U
-3g5yACwYnA\$_13	5.399	5.433	15/269/29/29	14/1/0
-3g5yACwYnA\$_2	9.231	9.267	14/461/47/47	12/0/2
-3g5yACwYnA\$_3	14.328	14.367	29/716/73/73	21/6/2
-3g5yACwYnA\$_9	8.696	8.767	23/434/45/45	19/3/1
-3nNcZdcvU\$_5	7.789	7.867	18/389/40/39	16/0/2
-571d8cVauQ\$_0	4.992	5.067	12/249/27/26	7/0/5
-571d8cVauQ\$_5	15.115	15.167	43/755/77/77	41/1/1
-6rXp3zJ3kc\$_8	12.738	12.800	34/636/65/65	30/1/3
-9y-fZ3swSY\$_0	6.757	6.833	22/337/35/35	11/1/10
-9y-fZ3swSY\$_4	2.665	2.700	9/132/15/15	4/3/2
-9y-fZ3swSY\$_8	4.917	4.967	12/245/26/23	12/0/0

表 3.8 全部 100 条特征与时序结果 (续)

样本标识	A 秒	V 秒	T/A/V/F 长度	W/P/U
-AUZQgSxyPQ\$_\$2	22.405	22.467	41/1119/113/113	15/3/23
-HeZS2-Prhc\$_\$2	8.151	8.200	16/407/42/42	11/2/3
-HwX2H8Z4hY\$_\$2	3.916	3.967	7/195/21/5	0/0/7
-HwX2H8Z4hY\$_\$5	5.544	5.600	9/276/29/10	7/0/2
-HwX2H8Z4hY\$_\$6	3.256	3.300	7/162/18/11	5/1/1
-HwX2H8Z4hY\$_\$9	7.636	7.733	22/381/40/0	6/2/14
-I_e4mIh0yE\$_\$1	7.444	7.500	18/371/39/39	18/0/0
-I_e4mIh0yE\$_\$3	8.994	9.033	22/449/46/46	17/0/5
-MeTTeMJBNC\$_\$0	9.218	9.300	21/460/48/47	20/0/1
-MeTTeMJBNC\$_\$13	5.256	5.300	14/262/28/28	12/0/2
-MeTTeMJBNC\$_\$7	10.411	10.467	31/520/54/54	31/0/0
-NFrJFQijFE\$_\$1	5.659	5.680	16/282/29/0	0/0/16
-NFrJFQijFE\$_\$2	6.698	6.760	18/334/35/0	0/0/18
-RfYyzHpjk4\$_\$11	5.075	5.133	17/253/27/27	13/3/1
-RfYyzHpjk4\$_\$2	5.392	5.467	25/269/29/29	22/3/0
-RfYyzHpjk4\$_\$8	4.532	4.567	17/226/24/24	16/0/1
-THoVjtIkeU\$_\$12	14.806	14.833	39/740/75/75	35/0/4
-THoVjtIkeU\$_\$2	4.231	4.267	10/211/23/23	10/0/0
-THoVjtIkeU\$_\$6	7.983	8.033	30/398/41/41	27/0/3
-UUCSKoHeMA\$_\$0	7.732	7.800	18/386/40/39	16/2/0
-UacrmKiTn4\$_\$10	7.242	7.267	18/361/38/38	18/0/0
-UacrmKiTn4\$_\$4	4.682	4.733	14/233/25/25	13/0/1
-UuX1xuaiiE\$_\$0	3.576	3.633	9/178/20/29	8/1/0
-UuX1xuaiiE\$_\$1	10.267	10.300	27/513/53/105	24/2/1
-UuX1xuaiiE\$_\$3	4.038	4.100	9/201/22/22	7/1/1
-UuX1xuaiiE\$_\$6	7.944	8.000	22/396/41/41	17/2/3
-a55Q6RWvTA\$_\$3	22.083	22.133	65/1103/112/116	61/2/2
-aNfi7CP8vM\$_\$7	8.538	8.567	18/426/44/44	12/2/4
-aqamKhZ1Ec\$_\$0	10.890	10.967	14/544/56/56	6/5/3
-dxftGcXJoc\$_\$0	20.410	20.500	40/1020/104/81	30/1/9
-dxftGcXJoc\$_\$1	16.018	16.067	37/800/82/82	32/4/1
-dxftGcXJoc\$_\$2	16.633	16.667	34/831/85/85	32/0/2
-dxftGcXJoc\$_\$6	12.628	12.700	28/631/65/65	26/1/1
-egA8-b7-3M\$_\$1	10.156	10.200	20/507/52/52	15/4/1
-egA8-b7-3M\$_\$13	4.024	4.100	11/200/22/22	11/0/0
-egA8-b7-3M\$_\$16	5.483	5.533	11/273/29/29	11/0/0
-egA8-b7-3M\$_\$17	7.095	7.167	16/354/37/37	15/1/0
-egA8-b7-3M\$_\$18	8.266	8.333	22/413/43/43	21/1/0
-egA8-b7-3M\$_\$20	6.474	6.533	20/323/34/34	20/0/0
-egA8-b7-3M\$_\$26	5.921	5.967	15/295/31/31	14/0/1
-egA8-b7-3M\$_\$6	6.183	6.233	12/308/32/32	11/0/1
-egA8-b7-3M\$_\$9	4.936	5.000	10/246/26/26	10/0/0
-hnBHBN8p5A\$_\$6	6.333	6.380	13/316/33/17	0/0/13
-hnBHBN8p5A\$_\$7	7.309	7.339	13/365/38/29	0/0/13
-iRBcNs9oI8\$_\$3	5.538	5.572	8/276/29/29	0/0/8

表 3.8 全部 100 条特征与时序结果 (续)

样本标识	A 秒	V 秒	T/A/V/F 长度	W/P/U
-iRBcNs9oI8\$_\$6	2.820	2.836	5/140/15/15	0/0/5
-iRBcNs9oI8\$_\$7	4.006	4.004	9/200/21/21	0/0/9
-iRBcNs9oI8\$_\$8	8.026	8.041	21/401/41/41	0/0/21
-iRBcNs9oI8\$_\$9	3.374	3.403	5/168/18/13	0/0/5
-lzEya4AM_4\$_\$5	7.570	7.633	19/378/39/39	16/1/2
-lzEya4AM_4\$_\$6	14.740	14.767	43/736/75/75	39/2/2
-mJ2ud6oKI8\$_\$1*	6.055	6.073	13/302/32/0	0/0/13
-mJ2ud6oKI8\$_\$2*	5.702	5.706	11/284/30/0	0/0/11
-mJ2ud6oKI8\$_\$6	2.228	2.236	5/111/12/12	0/0/5
-mJ2ud6oKI8\$_\$8	4.171	4.171	11/208/22/22	0/0/11
-mJ2ud6oKI8\$_\$9	6.909	6.940	22/345/36/36	0/0/22
-mqbVkbCndg\$_\$0	6.385	6.467	14/319/34/34	14/0/0
-qDkUB0GgYY\$_\$6	4.615	4.667	16/230/24/24	9/0/7
-ri04Z7vwnc\$_\$0	2.763	2.794	8/137/15/0	0/0/8
-ri04Z7vwnc\$_\$2	5.913	5.963	16/295/31/12	0/0/16
-ri04Z7vwnc\$_\$5	3.440	3.461	8/171/18/18	0/0/8
-s9qJ7ATP7w\$_\$0	6.711	6.800	24/335/35/35	18/0/6
-s9qJ7ATP7w\$_\$1	4.644	4.667	11/231/24/24	10/0/1
-s9qJ7ATP7w\$_\$4	4.247	4.300	9/212/23/16	8/0/1
-s9qJ7ATP7w\$_\$5	8.398	8.433	19/419/43/43	18/0/1
-s9qJ7ATP7w\$_\$6	2.315	2.367	5/115/13/10	5/0/0
-s9qJ7ATP7w\$_\$7	6.839	6.900	28/341/36/23	26/2/0
-s9qJ7ATP7w\$_\$8	3.184	3.233	12/158/17/17	9/0/3
-t217m2on-s\$_\$2	5.630	5.667	12/281/29/29	11/0/1
-t217m2on-s\$_\$7	17.026	17.067	45/851/87/87	43/1/1
-tANM6ETL_M\$_\$3	6.604	6.667	22/329/35/35	20/1/1
-tPCytz4rww\$_\$10	4.679	4.733	12/233/25/25	10/0/2
-tPCytz4rww\$_\$11	5.379	5.467	17/268/29/29	15/0/2
-tPCytz4rww\$_\$12	11.736	11.767	26/586/60/60	20/0/6
-tPCytz4rww\$_\$16	7.139	7.200	16/356/37/37	13/0/3
-tPCytz4rww\$_\$18	6.569	6.633	16/328/34/34	16/0/0
-uywlfIY0S8\$_\$4	5.881	5.967	18/293/31/31	16/0/2
-vxjVx0eScU\$_\$4	9.037	9.067	21/451/47/47	18/3/0
-wMB_hJL-3o\$_\$7	5.976	6.033	22/298/31/30	22/0/0
-wny00Az3g8\$_\$0	3.274	3.333	9/163/18/18	9/0/0
-wny00Az3g8\$_\$1	6.777	6.833	22/338/35/35	22/0/0
-wny00Az3g8\$_\$2	6.523	6.567	23/325/34/34	23/0/0
-wny00Az3g8\$_\$3	6.100	6.133	20/304/32/32	19/0/1
-wny00Az3g8\$_\$5	6.741	6.800	20/336/35/35	19/1/0
-wny00Az3g8\$_\$7	7.910	8.000	29/395/41/41	25/1/3
-wny00Az3g8\$_\$9	6.043	6.100	20/301/32/32	20/0/0
-yRb-Jum7EQ\$_\$1	29.110	29.167	49/1455/147/167	1/0/48
-yRb-Jum7EQ\$_\$5	13.045	13.133	25/651/67/67	1/0/24
-yRb-Jum7EQ\$_\$6	11.243	11.200	19/561/57/57	0/0/19

4 问题二：局部缺失下的情感预测

4.1 问题分析与建模假设

本问在三模态局部连续区间不可用时，利用其余观测预测情感极性与强度，比较缺失模态、位置和长度对结果的影响。

采用附件 2 与附件 3 的 `aligned_50` 版本。对齐意味着不同模态以相同序列位置组织，不能据此认定各位置具有相同持续秒数。附件 2 未提供逐词时间戳，因此缺失长度以有效特征位置数及比例表述，以原特征索引保留位置。

建模采用以下可检验假设。第一，字段内相同样本索引与相同对齐位置具有一致的组织含义。第二，依题意，有效区域内音视频整条特征向量为零表示不可观测，单个坐标为零仍是合法观测。第三，在未提供可靠时间戳的条件下，可用固定位置规则研究局部缺失敏感性，其结果用于解释所构造缺失模式的敏感性。第四，监督标签遵循负值、零值、正值分别对应负向、中性、正向的定义。

尾部各模态同时为零且缺少分隔词元时，保留长度歧义标记。附件 3 对齐版的 27 条样本有 131 个未知词占位，对应音视位置同时全零、文本注意力为 1；本文所列结果采用保留占位的固定输入口径，位置存在与词义可用状态分别记录。

4.2 输入组织与掩码

训练数据包含 `text_bert`、`audio`、`vision` 及标签。文本统一使用 `text_bert` 中的词元编号；训练与专项推理保持相同输入接口。训练、验证与测试共 4850 条样本已完成本地 BERT 分词编号核验。附件 3 的 `text_bert` 虽为浮点存储，读取时先验证数值有限且为整数，再转为整型编号。

$$X_i^a \in \mathbb{R}^{T \times 74}, \quad X_i^v \in \mathbb{R}^{T \times 35}, \quad T = 50 \quad (4.1)$$

表 4.1 主要符号与维度

符号	含义	维度或范围
i, j, m	样本、位置、模态索引	$m \in \{t, a, v\}$
t_i	文本词元编号	50; 编号 0 至 30521
X_i^a, X_i^v	语音与视觉输入	$50 \times 74, 50 \times 35$
v_{ij}	有效位置标记	0 或 1
o_{ij}^m, d_{ij}^m	原观测标记与人工缺失标记	0 或 1
$\tilde{o}_{ij}^m$	施加缺失后的可用标记	0 或 1
c_i, y_i	极性标签与强度标签	$\{0, 1, 2\}; [-3, 3]$
$p_i, \hat{y}_i$	三类概率与预测强度	概率单纯形; $[-3, 3]$
h_i^t, h_i^a, h_i^v	三模态投影表示	128, 64, 64
a_i, z_i	三模态可用比例与融合表示	3, 128

有效位置通过文本注意力、词元编号及音视频非零观测的并集确定可辨识边界，排除位置 0 与 CLS、SEP 特殊词元。区域内部连续全零仍保留其位置，而不压缩序列。观测掩码则分别判断文本注意力与编号有效性、音视频有限性和整向量全零情况。两类掩码分离，使填充、特殊词元与真实缺失具有不同语义。

$$\tilde{o}_{ij}^m = v_{ij} o_{ij}^m (1 - d_{ij}^m) \quad (4.2)$$

式(4.2)中的 $d=1$ 表示人工移除信息， $\tilde{o}=1$ 表示模型实际可使用该模态位置。人工缺失操作在编码之前生效。原观测掩码在标准化前确定并保存，不能因为标准化后某些数值恰好为零而重新判为缺失。

4.3 鲁棒多模态预测模型

4.3.1 训练集统计量与输入处理

不同模态的数值尺度差异会影响优化。我们仅使用当前拟合子集内可观测位置估计每个音视频坐标的均值与总体标准差；内部三折各自重新估计，官方完整训练后固定一份统计量用于验证、测试与附件 3。

$$\mu_k^m = \frac{\sum_{i,j} o_{ij}^m x_{ijk}^m}{\sum_{i,j} o_{ij}^m} \quad (4.3)$$

$$\sigma_k^m = \max \left(\sqrt{\frac{\sum_{i,j} o_{ij}^m (x_{ijk}^m - \mu_k^m)^2}{\sum_{i,j} o_{ij}^m}}, 10^{-5} \right) \quad (4.4)$$

$$\tilde{x}_{ijk}^m = \tilde{o}_{ij}^m \text{clip}((x_{ijk}^m - \mu_k^m)/\sigma_k^m, -10, 10) \quad (4.5)$$

式(4.3)与式(4.4)的求和仅覆盖拟合子集， m 取语音或视觉。标准差下界为 10^{-5} ，标准化后固定裁剪至 $[-10, 10]$ 以限制极端数值的影响；该规则在实验前已固定，不依据验证结果改变。不可观测向量置零但另保留掩码，因此模型不会把占位零当成正常测量。

4.3.2 编码前屏蔽与文本上下文表示

文本编码器采用 `bert-base-uncased` 通用预训练权重 [7, 8]：12 层、12 个注意力头、768 维隐状态和 3072 维前馈层，保留完整 30522 词表及前 50 个位置嵌入。词元、位置与 `segment` 嵌入经 `LayerNorm`、`dropout` 后送入 `Transformer`。

对于缺失的普通词元，先将编号置为占位值并从注意力键中屏蔽，再进行上下文编码；CLS 与可辨认的 SEP 保留为结构边界，CLS 位置始终开启以避免全屏蔽注意力的数值问题。汇总仅使用实际观测词元，特殊词元与缺失位置不进入均值。位置与边界信息作为结构输入保留。

$$\text{Attn}(Q, K, V) = \text{softmax}(QK^\top/\sqrt{64} + B)V \quad (4.6)$$

式(4.6)给出单个注意力头的核心计算。 Q 、 K 、 V 为线性投影，头宽为 64； B 在不可用键位置取 -10000 ，其余位置取 0。实现使用残差连接、后置 `LayerNorm` 和 `GELU` 前馈变换。对于缺失位置形成的查询隐状态，不在后续池化中采用，也不允许其作为有效键传递给其他位置。

$$\bar{h}_i^t = \frac{\sum_{j=1}^T \tilde{o}_{ij}^t H_{ij}}{\max(1, \sum_{j=1}^T \tilde{o}_{ij}^t)} \quad (4.7)$$

H 为最终文本隐状态。式(4.7)的分母截为至少 1 避免空序列除零，池化结果经 768→128 线性层、`LayerNorm` 与 `GELU`；若文本完全不可用，投影后的表示再次乘以可用性指示，使其严格为零。文本完全不可用时，其投影向量严格置零。

4.3.3 音视频汇总与多模态融合

$$\bar{x}_i^m = \frac{\sum_{j=1}^T \tilde{o}_{ij}^m \tilde{x}_{ij}^m}{\max(1, \sum_{j=1}^T \tilde{o}_{ij}^m)}, \quad m \in \{a, v\} \quad (4.8)$$

语音和视觉采用观测掩码均值汇总，再分别通过 74→64 与 35→64 的线性层、`LayerNorm` 和 `GELU`。均值编码在小样本条件下参数量较低、实现稳定，但不显式

区分可见片段内部的细粒度顺序，该汇总保留可见片段的平均信息。完全缺失的模态输出置零。

$$a_i^m = \frac{\sum_j \tilde{o}_{ij}^m}{\max(1, \sum_j v_{ij})}, \quad z_i = \text{GELU}(W_f[h_i^t; h_i^a; h_i^v; a_i] + b_f) \quad (4.9)$$

式(4.9)将 128 维文本、64 维语音、64 维视觉和 3 维可用比例拼接成 259 维向量，再映射为 128 维融合表示，训练 dropout 为 0.2。可用比例向融合层提供各模态剩余观测量。

$$p_i = \text{softmax}(W_c z_i + b_c), \quad \hat{c}_i = \arg \max_k p_{ik}, \quad \hat{y}_i = 3 \tanh(w_r^T z_i + b_r) \quad (4.10)$$




图 4.1 模型结构与编码前缺失处理。长度 50 为特征位置上限，不代表 50 秒。融合输入包含三模态表示及可用比例。

分类头输出三类 softmax 概率，回归头通过 $3\tanh$ 限制强度范围。标签约定 0、1、2 分别为负向、中性、正向。两头共享融合表示但分别监督，因而可能出现类别与强度符号不一致；本文保存两个任务各自的输出。

4.3.4 类别平衡目标函数

既有模型在三类任务上整体表现并不均衡。训练集负向、中性、正向样本量分别为 967、758、1670，最多与最少类别之比约为 2.20。该分布偏斜为检验类别平衡策略提供了动机，但不足以证明中性类别错误完全由样本数量造成；语义边界、表示能力和优化过程同样可能影响结果。

以类别频率调整经验风险 [9, 10]，比较不加权、平方根逆频率与逆频率三个强度。设当前拟合子集含 N 条样本、第 c 类数量为 n_c ， $C=3$ ，各内部折独立计数。

$$u_c = (N/(Cn_c))^\alpha, \quad w_c = u_c / (C^{-1} \sum_{k=0}^{C-1} u_k), \quad \alpha \in \{0, 0.5, 1\} \quad (4.11)$$

$\alpha=0$ 、0.5、1 分别对应不加权、平方根逆频率和逆频率。最终采用 $\alpha=1$ ，权重从第 1 轮开始作用。公共缩放在加权交叉熵的分子分母中相互抵消，因此将类别权重的

算术均值规范为 1 不改变目标；若当前拟合子集缺少某类，程序明确报错而不生成无穷权重。

$$\mathcal{L}_B = -\frac{\sum_{i \in B} w_{c_i} \log p_{i,c_i}}{\sum_{i \in B} w_{c_i}} + \frac{1}{|B|} \sum_{i \in B} H_1(\hat{y}_i - y_i) \quad (4.12)$$

$$H_1(e) = \begin{cases} e^2/2, & |e| \leq 1, \\ |e| - 1/2, & |e| > 1. \end{cases} \quad (4.13)$$

c_i 始终表示离散类别， y_i 始终表示连续强度， B 表示有效批量；分类概率 p 的第二下标选择真实类别。加权交叉熵强调较少类别的分类误差，**Huber** 阈值固定为 1，对较大回归残差采用线性增长。两任务系数为 1:1。类别权重不增加推理参数，也不将 **softmax** 概率自动校准为正确率。

4.3.5 连续缺失训练

$$k_i = \min(n_i, \max(1, \lfloor rn_i + 0.5 \rfloor)), \quad n_i = \sum_j v_{ij} \quad (4.14)$$

对每个训练样本，以 0.7 概率选取一个模态施加连续缺失，模态均匀抽样，比例 r 从 0.1、0.3、0.5 中均匀抽样。式(4.14)适用于有效长度 $n_i > 0$ ；空序列不额外移除位置。连续性按有效位置的顺序定义，随机起点保证所选片段在边界内。该增强使优化目标包含人工缺失下的监督风险，但不能保证所有缺失条件都改善，其作用由消融实验判断。

4.4 求解流程与实验协议

表 4.2 固定训练参数

步骤	操作
1	固定官方划分；在训练集内按原视频标识生成三折，各折视频组不重叠。
2	各折只以拟合样本估计标准化参数和类别频率；按阶段协议固定预训练词表。
3	初始化预训练编码器和预测头；每个批量在编码前按规则生成局部缺失掩码。
4	计算加权交叉熵与 Huber 损失，按有效批量累积梯度，裁剪后以 AdamW 更新。
5	内部每轮评价完整输入和九类固定缺失场景；按预定分数保存最佳轮次并早停。
6	对完成三折且满足保护条件的候选排序；以最佳轮数中位数固定正式训练轮数。
7	仅在官方训练集重新拟合，完成三个种子的验证确认；冻结模型后才开展描述性测试。

表 4.3 求解流程与实验协议

项目	取值
编码器学习率	2×10^{-5}
投影与预测头学习率	5×10^{-4}
优化器与权重衰减	AdamW; 0.01; 偏置和归一化参数不衰减
有效批量与梯度裁剪	32; 梯度范数上限 1
学习率计划	前 10% 更新线性预热, 其后线性衰减
内部训练预算	12 层模型最多 6 轮; 连续 3 轮无改善早停
训练与推理精度	CUDA BF16 自动混合精度训练; FP32 评价; 关闭 TF32
随机种子	三折分组 240924; 确认 42、2026、3407
连续缺失增强	概率 0.7; 三模态与三个比例均匀抽样
损失权重	加权交叉熵:Huber=1:1

AdamW 采用解耦权重衰减 [11]。有效批量固定为 32; 显存不足时允许微批量缩至 16 或 8 并累计贡献, 不能对类别组成不同的微批量加权均值简单平均。对 B 的互不相交分块 B_j , 分类分母始终使用完整 B 的权重和, 回归分母始终使用 $|B|$ 。固定轮数确认阶段在训练结束后一次评价, 不逐轮利用官方验证选检查点。

$$\mathcal{L}_B = \sum_j \left[-\frac{\sum_{i \in B_j} w_{c_i} \log p_{i,c_i}}{\sum_{i \in B} w_{c_i}} + \frac{\sum_{i \in B_j} H_1(\hat{y}_i - y_i)}{|B|} \right] \quad (4.15)$$

$$\text{MAE} = \frac{1}{N} \sum_i |\hat{y}_i - y_i|, \quad S = \frac{1}{2} \overline{F1}_{miss} + \frac{1}{2} (1 - \overline{MAE}_{miss}/6) \quad (4.16)$$

除式(4.16)的选择分数外, 按共用评价约定报告 Accuracy、Macro-F1、各类别 F1、MAE 与 Pearson。F1 对三类等权求平均, 分母为零的类别按 0 计; Pearson 在样本不足或真值、预测恒定时记为未定义并说明原因, 不填造数值。内部选择分数 S 仅是团队预先固定的比较准则, 不是比赛官方评分公式。

验证主场景为文本、语音、视觉分别缺失 10%、30%、50%, 共 9 类; 每个样本的随机起点由固定种子、样本 ID 和场景名称的 SHA256 确定。补充场景采用前部、中部、后部以及分成最多三段的多个短区间, 共 36 类。多个短片段不保证彼此间隔非零, 极短样本中可能合并, 报告按实际移除位置统计而非假定严格分离。

所有候选共享场景定义与样本顺序。 S 取九场景指标的算术平均, 不是将场景样本拼接后计算一次 F1。完整输入 clean 表示没有额外人工缺失, 仍可能包含原始自然缺失。人工选择的位置若原本不可观测, 不会产生额外的信息移除; 因此同时记录所选位置数和新增不可观测位置数。

类别权重候选须至少在两个内部折提高 S , 且完整输入三折平均 Macro-F1 下降不超过 0.01、MAE 增加不超过 0.03; 取合格者中平均 S 最高者进行三个同种子确认。正式训练固定为内部最佳轮数中位数 4 轮, 部署使用种子 42。

官方验证集用于候选确认与缺失规律分析, 历史研究也曾查看测试表现。测试结果作为固定方案的描述性评价; 模型比较的结论限定于所列划分与开发协议。

4.5 模型开发与主结果

4.6 验证结果与模型比较

4.6.1 预训练方案与缺失增强对照

表 4.4 内部三折平均结果

模型	完整 F1	完整 MAE	缺失 F1	缺失 MAE	S
两层蒸馏基线	0.5575	0.6938	0.5475	0.7073	0.7148
12 层裁剪词表 + 缺失训练	0.6025	0.6094	0.5857	0.6301	0.7403
12 层完整词表 + 缺失训练	0.6218	0.6050	0.6038	0.6241	0.7499
12 层完整词表无缺失增强	0.6231	0.6031	0.6044	0.6227	0.7503

表4.4中 F1 为 Macro-F1，数值为视频分组内部三折的算术均值。完整词表方案与关闭缺失增强方案采用相同训练协议。关闭增强后 S 增加 0.0004、缺失 F1 增加 0.0006、缺失 MAE 降低 0.0015；本对照未显示连续缺失增强的收益，类别加权后的关闭增强对照尚无结果。

完整词表相对于裁剪词表 12 层模型，三折平均 S 变化为 +0.0096，完整 F1 变化为 +0.0193，完整 MAE 变化为 -0.0044。该比较提供词表保留策略的经验依据；由于词表维度变化也会影响同种子下后续随机初始化序列，且开发阶段只使用一个训练种子，不能将差异完全归因为未见词元本身。

连续缺失训练相对于不增强方案的三折平均 S 变化为 -0.0004，缺失平均 F1 变化为 -0.0006，缺失平均 MAE 变化为 +0.0015。该结果未显示连续缺失训练在本配置下具有更高的综合得分，不能把缺失增强描述为已被充分证明有效的创新点。两组模型均按自己的内部验证分数选最佳轮次，因此这里比较的是包含早停的训练策略，而非同一固定轮数的纯损失扰动。

保留的两层实验分别检验文本单模态、多模态输入、连续缺失增强、蒸馏与随机初始化；四层实验检验另一种编码深度。蒸馏模型与四层模型的内部 S 差距很小，不能仅凭排序宣称其具有显著优势。两层与 12 层模型训练轮数及训练目标可能不同，跨结构的总差异不应包装成严格的单因素消融。

4.6.2 类别权重的内部配对比较

内部开发继续使用不加权基线按视频分组的三折。每个候选仅改变分类权重强度，随机种子 42，最多 6 轮、早停耐心 3 轮；标准化、原始预训练权重、完整词表、连续缺失训练概率 0.7 和 AdamW 参数保持一致。以九类主要缺失场景上的既有综合分数 S 选择最佳轮次，再用最佳轮数中位数确定官方训练确认的固定轮数。

为确认软件修改没有改变对照条件，先重跑不加权配置的第 1 折。重跑与不加权基线对应模型的 217 个参数张量逐项完全一致，最大绝对差为 0.0，选择分数差为 0.0。该检查支持在同环境与同配方下复用旧对照；不能推广为跨硬件逐位一致保证。

表 4.5 内部三折算术均值

配置	完整 F1	完整 MAE	缺失 F1	缺失 MAE	S
不加权参照	0.6218	0.6050	0.6038	0.6241	0.7499
平方根权重	0.6294	0.6059	0.6092	0.6250	0.7525
逆频率权重	0.6327	0.6147	0.6124	0.6325	0.7535

平方根权重在 2/3 折提高 S，平均差为 +0.00263；中性 F1 均值为 0.4611。其内部保护条件判定为通过。该比较使用各配置在内部验证上选定的最佳轮次，反映受同一预算约束的整体训练方案差异，不是未经选择的泛化性能估计。

逆频率权重在 2/3 折提高 S，平均差为 +0.00360；中性 F1 均值为 0.4646。其内部保护条件判定为通过。该比较使用各配置在内部验证上选定的最佳轮次，反映受同一预算约束的整体训练方案差异，不是未经选择的泛化性能估计。

4.6.3 三种子主结果与性能取舍

表 4.6 官方验证集三种子确认均值与样本标准差

指标	不加权基线参照	类别平衡模型	均值差
完整 Accuracy	0.6369 ± 0.0042	0.6277 ± 0.0060	-0.0092
完整 Macro-F1	0.5959 ± 0.0059	0.6163 ± 0.0040	+0.0204
完整 MAE	0.5783 ± 0.0060	0.5790 ± 0.0099	+0.0006
完整 Pearson	0.6815 ± 0.0063	0.6816 ± 0.0086	+0.0001
负向类别 F1	0.6770 ± 0.0109	0.6728 ± 0.0070	-0.0042
中性类别 F1	0.3871 ± 0.0133	0.4808 ± 0.0062	+0.0937
正向类别 F1	0.7238 ± 0.0020	0.6954 ± 0.0140	-0.0284
缺失平均 Macro-F1	0.5862 ± 0.0018	0.6026 ± 0.0013	+0.0164
缺失平均 MAE	0.5906 ± 0.0067	0.5909 ± 0.0101	+0.0002
内部选择分数 S	0.7439 ± 0.0009	0.7521 ± 0.0008	+0.0082

均值差由未舍入结果计算，表中均值与标准差统一显示四位小数。

两层蒸馏到完整编码基线的改善涉及编码深度、词表及训练方案变化，不能归为单一因素。类别平衡方案保持编码结构并调整分类损失，三种子完整 Macro-F1 均改善，但 Accuracy 和正向 F1 的均值下降。当前取舍由此前固定的目标与保护条件决定，不代表所有应用场景都会优先选择该模型。

4.6.4 固定模型的不确定性分析

区间估计以原视频为重采样单位，在验证集 239 个视频组中有放回抽取相同数量的组，保留组内全部片段及重复次数，共进行 2000 次。每次对两个模型和所有场景使用完全相同的抽样组，然后重新计算 F1 与 MAE 的差值。该配对设计保留组内相关性和模型比较的样本配对。95% 区间取差值分布的 2.5% 与 97.5% 分位点，不是三个种子均值的置信区间，也未校正此前模型搜索带来的选择偏差。

表 4.7 种子 42 模型差异的 95% 视频分组配对 Bootstrap 区间

场景	指标	差值	区间
clean	macro_f1	+0.0220	[-0.0079, +0.0525]
clean	mae	-0.0005	[-0.0058, +0.0050]
missing_average	macro_f1	+0.0170	[-0.0052, +0.0397]

表 4.7 种子 42 模型差异的 95% 视频分组配对 Bootstrap 区间 (续)

场景	指标	差值	区间
missing_average	mae	-0.0007	[-0.0053, +0.0040]

表4.7对 239 个视频组进行 2000 次配对 Bootstrap，两个模型与所有场景使用相同抽样。所列区间均跨零，固定模型的点估计差异仍有不确定性。

4.7 局部缺失规律

4.7.1 模态类型与缺失比例




图 4.2 官方验证集连续缺失比例响应。线为三种子均值，阴影为 $\pm$ 一个样本标准差，0% 为完整输入；横轴是名义特征位置比例，非秒数。各行共用纵轴，保留非单调变化。Macro-F1 越高越好，MAE 越低越好。

表 4.8 最终模型种子 42 的主缺失场景

模态	比例	Macro-F1	$\Delta F1$	MAE	ΔMAE
文本	10%	0.5936	-0.0181	0.5863	+0.0109
文本	30%	0.5643	-0.0474	0.6091	+0.0338
文本	50%	0.5515	-0.0603	0.6367	+0.0614
语音	10%	0.6085	-0.0033	0.5752	-0.0001
语音	30%	0.6160	+0.0042	0.5764	+0.0011
语音	50%	0.6227	+0.0110	0.5760	+0.0007
视觉	10%	0.6178	+0.0061	0.5746	-0.0007
视觉	30%	0.6158	+0.0041	0.5732	-0.0021

表 4.8 最终模型种子 42 的主缺失场景（续）

模态	比例	Macro-F1	$\Delta F1$	MAE	ΔMAE
视觉	50%	0.6202	+0.0085	0.5749	-0.0005

种子 42 在文本连续缺失 50% 时 Macro-F1 为 0.5515，相对完整输入变化为-0.0603；MAE 变化为 +0.0614。音视频响应较小且存在非单调变化，可能与当前均值表示、文本主导或噪声移除有关，但本实验不能单独识别这些机制。三种子曲线的阴影只刻画训练种子波动，不覆盖缺失起点重复抽样的不确定性。

4.7.2 缺失位置与片段形状

固定文本缺失比例 50% 时，前部、中部、后部的 Macro-F1 分别为 0.5586、0.5313、0.5152。该模型在这一固定划分和实现下对后部缺失更敏感；位置以有效特征顺序定义，没有依据将其解释为特定秒数、情绪转折或结尾词的因果作用。补充热图保留全部 36 类场景和不利结果。

片段形状比较的差值均为多个短片段减单长片段。类别平衡模型文本缺失 10% 和 30% 时，多段 F1 较高但 MAE 也略高；50% 时多段 F1 反而较低而 MAE 略低。不同评价任务的变化并不一致，不能得出多段缺失普遍更容易或更困难的结论。

名义比例 10%、30%、50% 对应的样本平均实际位置比例依次为 11.20%、30.74%、51.64%。差异源于按有效长度取整及至少移除一个位置；若所选位置原已不可观测，新增信息损失少于所选位置数。这两类数量分别保留在实验档案中。




图 4.3 类别平衡模型种子 42 在官方验证集 728 条样本的 36 类补充缺失场景。数值为相对同模型完整输入的变化；上排 $\Delta \text{Macro-F1}$ 越负越差，下排 ΔMAE 越正越差。同一指标共用色标，位置比例不是时间。

4.8 分类与回归误差




图 4.4 固定种子 42 的完整官方验证集混淆矩阵，两个模型均使用相同 728 条样本。格内同时给出计数与真实类别内比例，两图使用共同色标。

类别平衡改变不同类别的错误代价。种子 42 模型中，中性 F1 由 0.3810 提高至 0.4810，正向 F1 由 0.7231 降至 0.6792，Accuracy 由 0.6332 降至 0.6209。三种种子结果呈现同样的类别取舍。

三分类与强度回归是不同损失下的两个输出。若将所有非零回归值直接按符号分为正负，而只有精确零对应中性，则预测为中性的样本几乎都会被计入“类别与回归不一致”。这一严格定义容易把接近零的正常连续输出混入真正的正负方向冲突。因此，应分解统计，而不能把总不一致率直接称为模型自相矛盾率。

表 4.9 完整验证集的严格符号不一致分解

模型	总不一致	中性类且回归非零	非中性正负相反	非中性且回归为零
不加权基线	140	131	9	0
类别平衡模型	249	236	13	0

该分解仅用于解释现有诊断指标，没有据官方验证重新设定回归阈值或改写预测。中性类别的精确率、召回率和 F1 仍按官方离散标签计算，强度误差仍按原连续标签计算。模型分别保存两个任务的监督输出。

种子 42 模型中，中性样本 184 条，正确识别 101 条，误判负向 29 条、正向 54 条。该计数对应类别平衡方案完整输入结果，不能与不加权基线混淆矩阵混用。




图 4.5 类别平衡方案最终模型种子 42 的完整官方验证集回归诊断， $n=728$ 。左图为实际二维计数，虚线为理想预测；右图为各真实类别的残差箱线图，保留离群点。箱体表示第 25 至 75 百分位，线为中位数，须线采用 1.5 倍四分位距规则，不是置信区间。

4.9 附件三全量预测与结果接口

30 条样本采用同一对齐版本、训练集标准化统计和种子 42 模型。按文件名及文件内序号构造样本标识，检查整数词元编号、形状、有限性与观测掩码后，输出三类概率、极性和强度。

表 4.10 附件 3 全部 30 条类别平衡模型预测

文件编号	预测类别	情感强度	最大类概率
附件 3_01	负向	-0.9664	0.9351
附件 3_02	中性	-0.0240	0.8249
附件 3_03	中性	0.2880	0.6327
附件 3_04	中性	0.4002	0.5492
附件 3_05	负向	-1.4878	0.9620
附件 3_06	正向	0.7274	0.7612
附件 3_07	中性	0.3212	0.4591
附件 3_08	负向	-0.1221	0.4424
附件 3_09	正向	1.1522	0.9127
附件 3_10	中性	-0.0761	0.8693
附件 3_11	正向	0.4640	0.5397
附件 3_12	正向	0.4631	0.4775
附件 3_13	正向	0.3951	0.5546
附件 3_14	负向	-0.8660	0.9331
附件 3_15	正向	0.4315	0.6484
附件 3_16	正向	1.4899	0.9466
附件 3_17	中性	0.2033	0.6264
附件 3_18	中性	0.4165	0.5085
附件 3_19	中性	-0.0275	0.4710
附件 3_20	中性	0.0469	0.7418

表 4.10 附件 3 全部 30 条类别平衡模型预测（续）

文件编号	预测类别	情感强度	最大类概率
附件 3_21	正向	0.3067	0.5091
附件 3_22	正向	0.4599	0.5061
附件 3_23	中性	0.2963	0.6255
附件 3_24	负向	-0.1566	0.4829
附件 3_25	中性	0.3507	0.7080
附件 3_26	正向	0.6527	0.7230
附件 3_27	正向	0.4871	0.5590
附件 3_28	中性	0.4902	0.5805
附件 3_29	正向	0.6848	0.6238
附件 3_30	中性	0.3920	0.7424

专项 CSV 保留 `sample_id`、`scenario`、`class_id`、`sentiment`、`intensity` 和三类概率，表内数值为显示而舍入，CSV 保留原计算精度。稳定标识使用文件名和文件内序号，与原始视频标识分开保存。附件 3 没有标签，其预测分布不用于调参，最大类概率也不是已校准的置信度。

文本编码的主要计算量为 $O(L(Td^2 + T^2d + Tdd_{ff}))$ ，其中 $T=50$ 、 $d=768$ 、 $L=12$ ；音视汇总分别为 $O(74T)$ 、 $O(35T)$ 。运行环境记录为 Python 3.10.18、PyTorch 2.8.0、CUDA 12.8、NumPy 2.2.6 和 scikit-learn 1.7.2。复算使用训练得到的模型权重与标准化参数，先构造同一观测掩码，再进行批量推理；预测 CSV 保留完整精度。

5 问题三：可解释融合与证据定位

5.1 建模假设

假设 1：题目给定的对齐位置可以作为三模态局部读出的共同索引。该索引用于模型计算；机器估计的媒体时间只用于证据回查，不假设其等于原音视特征的精确提取时间。

假设 2：无有效数值的音视行不提供局部观测信息，对应项和关联交互置零。缺失状态本身不被赋予正向、负向或中性含义；是否缺失以原始观测掩码判断。

假设 3：在上下文化局部编码之后，用单模态项与两两交互近似融合关系，不另设不可分解的融合残差。三方高阶作用未被显式建模，由此得到可核算性与表达能力之间的折中。

假设 4：单模态回归残差的条件方差可作为该模态读出的相对可靠性线索。此假设用于构造缩放系数；是否提高泛化性能需由数据检验，方差不直接视为分类置信度或人类证据可信程度。

5.2 数据观察与预处理

使用附件二训练与验证划分建立模型，附件四 20 条无标签样本用于专项预测与解释。

每条样本最多 50 个对齐位置，给定文本特征 768 维、语音特征 74 维、视觉特征 35 维，另有 BERT 词元编号、注意力掩码及类型编号。本模型选择 `text_bert` 输入预训练 BERT[7]，不把 `text` 与 `text_bert` 视为两个模态。剔除特殊词元和填充位置后保留原序列位置 `source_index`，文本隐状态经 `LayerNorm` 后回填到局部窗口。

语音、视觉全零行按无有效数值观测处理。对模态 m 的第 d 维，仅在训练集有效观测上计算均值 μ_{md} 和总体标准差 s_{md} ，并标准化为 $(x_{mjd} - \mu_{md})/s_{md}$ ；标准差小于 10^{-6} 时置为 1。缺失行保持为零且保留掩码，验证、测试和附件四复用训练统计，避免把待评价集合的信息用于归一化参数估计。

模型评估基于既有探索实验：历史研究中曾多次查看附件二测试表现，最终方案同时考虑已有性能与解释要求。因而本文报告的是单种子探索性比较，不能作为完全独立、确认性的模型优越性结论；附件四在正式展示中只报告模型输出。

5.3 模型建立

5.3.1 上下文化局部证据与成对交互

借鉴神经可加模型 [12] 与成对交互建模 [13]，采用“局部非线性编码—显式加性读出”的结构。BERT 提供语言上下文，局部编码保留证据位置，成对分支表达同位置的跨模态共同作用。可靠性缩放在样本层调整这些读出项，不额外设置无法核算的融合残差。预测及解释共享同一次前向中的实际数值。




图 5.1 不确定性融合网络。T/A/V 为文本/语音/视觉；每个分支的 4 维输出对应 q 及负向、中性、正向 logit 。

记 $m \in \{T, A, V\}$, j 为有效内容窗口。窗口宽度为 1；每模态局部编码器由逐行线性映射与 GELU、窗口拼接线性映射与 GELU 构成，投影维度与局部隐层均为 64。文本 BERT 隐状态先作 LayerNorm，再按 `source_index` 回填局部位置。用相同观测结构下的零输入编码作为参考，得到下式。参考为特征坐标基准，不代表真实中性情绪。

$$d_{mj} = E_m(x_{mj}, o_{mj}) - E_m(0, o_{mj}) \quad (5.1)$$

单模态读出为无偏置 $64 \rightarrow 4$ 线性映射。均值汇聚权重 ω_{mj} 正比于该窗口内有效观测数；成对权重 ω_{mnj} 以两端权重几何均值构造，限制在共同有效窗口，再按样本归一化。TA、TV、AV 各使用独立的秩 8 双线性投影，分别输出 4 维交互。

$$a_{mj} = \omega_{mj} W_m d_{mj}, \quad i_{mnj} = \omega_{mnj} V_{mn} [(P_{mn} d_{mj}) \odot (Q_{mn} d_{nj})] \quad (5.2)$$

P、Q、V 均不含偏置；某一模态没有有效观测时，该单项与关联交互严格为零。BERT 使单个文本读出含有全句上下文，因此局部值解释为该位置的上下文化读出。成对模块连接对齐位置，文本上下文来自 BERT，模型不另设音视跨位置注意力或三方高阶交互。

5.3.2 由残差方差驱动的可靠性融合

首先从未进行精度缩放的单项计算每模态四维净分数 $u_m = \beta + \sum_j a_{mj}$ ，同时统计各输出维度局部读出的绝对活性 $\sum_j |a_{mj}|$ 。拼接后得到 8 维输入，通过每模态一个 $8 \rightarrow 1$ 线性层预测有界对数方差。训练时活性来自模态丢弃后的单项，单模态监督仍使用丢弃前的实际单项。

$$v_m = -1 + 4 \tanh(w_m^T [u_m; \sum_j \text{abs}(a_{mj})] + b_m), \quad \sigma_m^2 = \exp(v_m) \quad (5.3)$$

$$p_m = \frac{\mathbf{1}_m \exp(-v_m)}{\sum_n \mathbf{1}_n \exp(-v_n)}, \quad \kappa_m = K p_m, \quad K = \sum_m \mathbf{1}_m \quad (5.4)$$

$\mathbf{1}_m$ 表示当前保留且可观测的模式。单项按 κ_m 缩放，成对项按 $\sqrt{(\kappa_m \kappa_n)}$ 缩放。精度相同时 $\kappa_m=1$ ，恢复基础加性读出；方差被限制在 $\exp(-5)$ 至 $\exp(3)$ 之间。方差监督针对单模态回归残差，它既不是分类概率校准，也不是融合后预测区间。归一化精度 p_m 是可靠性系数，其定义与模态净贡献占比不同。

$$s = \beta + \sum_{m,j} \kappa_m a_{mj} + \sum_{(m,n) \in \mathcal{P}, j} \sqrt{\kappa_m \kappa_n} i_{mnj} \quad (5.5)$$

$$q = s_0, \quad \ell = (s_1, s_2, s_3)$$

$\mathcal{P} = \{(T,A), (T,V), (A,V)\}$ 为无序模态对的集合，每个成对项只计入一次。

5.3.3 联合输出与模态贡献定义

回归原始输出 $r = 3 \tanh(q)$ 。冻结分类策略为中性 **logit** 加 -0.4 后取最大值： $\ell' = \ell + (0, -0.4, 0)$ ， $\hat{c} = \arg \max_c \ell'_c$ 。最终强度按类别保持符号一致：负向 $\min(r, -10^{-6})$ ，中性 0 ，正向 $\max(r, 10^{-6})$ 。所有主表 **MAE** 均评价该最终强度，同时另存 **raw_intensity**。分类和回归共享全部编码及交互参数，输出层有各任务对应的行，联合训练；主模型未启用有序分类头，但保留强度的有序辅助损失。

对每条样本，以预测类别 $\hat{c}$ 与最强竞争类别 c_2 的校准 **logit** 差 $M = \ell' \hat{c} - \ell' c_2$ 为分类解释目标。将所有 4 维读出投影到这一类别差后，记单模态总项 A_m 、交互总项 I_{mn} 。每个成对交互的一半分配给相关两端，得到模态净分数与位置净分数：

$$\Phi_m = A_m + \frac{1}{2} \sum_{n \neq m} I_{mn}, \quad \psi_{mj} = \tilde{a}_{mj} + \frac{1}{2} \sum_{n \neq m} \tilde{i}_{mnj} \quad (5.6)$$

$$M = \beta_M + \sum_m \Phi_m$$

$$\rho_m = \frac{\text{abs}(\Phi_m)}{\sum_n \text{abs}(\Phi_n)}, \quad m_{\text{ref}} = \arg \max_m \text{abs}(\Phi_m) \quad (5.7)$$

$\tilde{a}$ 和 $\tilde{i}$ 表示已缩放、已投影到解释目标的读出。 β_M 包括两个对应输出偏置之差，以及中性 -0.4 校准项对该类别差的影响。解释卡同时保留符号：正值支持预测类别相对于竞争类别，负值反对该判断。 ρ 采用模态净值的绝对值归一化，偏置 β_M 单列；它不同于把所有局部绝对值先相加得到的活性比例。若分母近零则标为未定义，主要模态不能强制指定。回归解释以 q 为目标同样核算，相应比例描述 q 的加性分解。动态可靠性与 **BERT** 上下文均随输入变化，因此当前分数项删除不等于重新运行被修改输入后的输出变化。

5.4 模型求解与训练方案

5.4.1 多任务目标函数

$$L = L_{\text{Huber}}(r, y) + 0.5 L_{\text{CE}}(\ell, c) + 0.1 L_{\text{ord}} + 0.001 L_{\text{pair}} + 0.1 L_{\text{uni}} + 0.1 L_{\text{neutral}} + 0.1 L_{\text{polarity}} + 0.1 L_{\text{NLL}} \quad (5.8)$$

Huber 阈值 $\delta=1$ 。Lpair 为每样本所有已缩放成对项回归分量的绝对值之和，再在批内平均。Luni 在实际可观测模态上平均 Huber 单模态回归损失与 0.5 倍单模态交叉熵；它使用 u_m 的回归、分类分量。Lneutral 使用中性 **logit** 减去正负 **logsumexp** 作为二分类 **log-odds**；Lpolarity 仅在非中性样本上对正负 **logit** 差进行二元交叉熵。

Lord 用固定带宽 0.3、温度 0.2 构造两个累计 logit: $((r+0.3)/0.2, (r-0.3)/0.2)$, 分别以 $1[c>0]$ 和 $1[c>1]$ 为目标计算二元交叉熵并平均; 该项不是启用独立的可学习有序头。

$$e_{im} = 3 \tanh(u_{im0}) - y_i$$

$$L_{\text{NLL}} = \frac{1}{2N_{\mathcal{O}}} \sum_{(i,m) \in \mathcal{O}} (\exp(-v_{im}) e_{im}^2 + v_{im}) \quad (5.9)$$

式(5.9)在批内所有实际可观测的“样本—模态”对上取平均, 记这些索引对的集合为 $\mathcal{O}$ 、数量为 $N_{\mathcal{O}}$; **abs** 表示绝对值。i 为样本索引, $u_{im,0}$ 为对应单模态读出的回归分量。模态丢弃不改变此项的实际观测监督范围。

异方差回归的 NLL 建模 [14] 用于单模态残差方差, 使可靠性模块获得可监督训练信号。该损失不是三模态贡献的监督真值, 预测方差的绝对大小不能直接等同于人类对证据可靠性的判断。整个模型用 AdamW 更新, BERT 编码层和其他层使用固定分组学习率, 学习率固定。

5.4.2 求解流程与关键参数

训练环境为 Python 3.11.15、PyTorch 2.5.1+cu124、NumPy 2.4.6 和 RTX 3090 Ti。推理加载固定检查点与训练统计, 使用与训练相同的对齐输入。

求解分为五步: ① 在附件二训练集估计有效观测的标准化统计量; ② 载入公开预训练 BERT, 初始化局部编码、成对读出与方差模块; ③ 按批次执行模态丢弃、联合前向与目标函数求导, 使用 AdamW 更新参数; ④ 每轮在验证集比较分类策略, 保存三个选优目标对应的检查点; ⑤ 选择固定检查点与决策策略, 在测试集计算评价指标, 在附件四输出预测及解释。附件四不参与上述训练和验证策略搜索。

表 5.1 主模型训练与推理参数

参数	冻结主模型设置
随机种子 / 批大小	17 / 32
BERT / 其他层学习率	2×10^{-5} / 3×10^{-4} , 固定
AdamW 权重衰减 / 梯度裁剪	0.01 (二维以上参数) / 1.0
窗口 / 行投影 / 局部维度 / 交互秩	1 / 64 / 64 / 8
局部 dropout / 模态丢弃率	0.2 / 0.1
最大轮次 / 早停耐心值	20 / 连续 4 轮三个选优目标均无刷新
实际轮数 / 采用检查点	9 / 第 5 轮
可训练 BERT 层 / AMP	12 层, embedding 和 pooler 冻结 / 关闭
总参数 / 可训练参数	109,555,007 / 85,127,231
分类最终策略	中性 logit 偏置 -0.4 ; 最大 logit 类别

每轮仅在验证集搜索策略: 441 组回归中性阈值和 31 个中性 logit 偏置, 共 472 个候选; 分别按 Macro-F1、Accuracy 及最终强度 MAE 维护独立最佳检查点。任一目标排序刷新即重置早停计数, 不是只监测训练损失。本文主表统一取验证 Macro-F1 策略, 各指标使用相同检查点和策略。第 5 轮之后训练损失继续降低但验证原始 MAE 未刷新, 支持保留早停; 增加训练上限不自动增加有效训练轮数。




图 5.2 主模型训练曲线。虚线为第 5 轮，实际第 9 轮停止。右图为原始强度 MAE，区别于主表最终强度 MAE。

5.4.3 评价指标与对比设置

附件二验证集的正向样本占 46.43%，负向和中性分别占 28.30% 和 25.27%，类别分布不均衡。因此同时采用准确率、Macro-F1 和中性 F1 评价分类，采用平均绝对误差 MAE 与 Pearson 相关系数评价强度。所有回归指标均以类别一致性处理后的最终强度计算。

各指标采用共用评价约定，三分类按负向、中性、正向计算，回归评价最终强度。

选择两个具有已训练检查点的开源适配基线。SELF-MM[15] 采用 BERT 文本编码、音视 LSTM、融合及单模态读出和中心驱动动态伪标签；本实现增加比赛三分类读出、有效观测打包与数值稳定处理。TETFN[16] 直接使用 MMSA 工具库 [17] 固定版本的网络源码，恢复对齐音视位置，增加比赛分类头及有界回归输出，并使用本地联合训练目标。二者均为比赛数据适配实验，不是原论文数据规模、训练目标和配置下的严格复现。

所有方法仅以 3395 条训练样本学习，在同一 728 条验证集上选轮次和策略；本表统一使用各自验证 Macro-F1 版本。主模型最终按分类 logit 决策，而两基线的验证最优策略为回归阈值决策，策略差异一并列出，避免把结果误认为统一最后一层阈值的比较。

5.4.4 基础性能与可视化分析

表 5.2 验证集（728 条）模型性能比较

模型	Acc(%)	Macro-F1	MAE	Pearson	中性 F1
SELF-MM 适配	64.56	0.6390	0.5491	0.6910	0.5145
TETFN 源码适配	64.01	0.6321	0.5730	0.6569	0.5012
不确定性融合（主）	65.11	0.6323	0.5397	0.6993	0.4822

表 5.3 附件二测试集（727 条）模型性能比较

模型	Acc(%)	Macro-F1	MAE	Pearson	中性 F1
SELF-MM 适配	66.16	0.6389	0.5966	0.6978	0.4712
TETFN 源码适配	65.61	0.6285	0.6226	0.6735	0.4355
不确定性融合（主）	68.64	0.6493	0.6006	0.7046	0.4506

表 5.4 模型选优轮次与决策策略

模型	检查点轮次	验证选定的最终策略
SELF-MM 适配	3	回归双阈值：-0.05 / 0.35
TETFN 源码适配	1	回归双阈值：0.00 / 0.55
不确定性融合（主）	5	中性 logit 偏置-0.4，取最大类别

主模型验证 Macro-F1 并非三者最高：SELF-MM 为 0.6390，主模型为 0.6323。相对表中按验证 Macro-F1 选择的 SELF-MM 参考配置，主模型在附件 2 测试中准确率高 2.48 个百分点、Macro-F1 高约 0.0104，而 MAE 稍高约 0.0040；相比表中 TETFN 参考配置，测试准确率、Macro-F1 和 MAE 均更优。这一比较限定于表中配置；上述方法进一步给出两类基线的其他参数结果。选择主模型同时考虑其原生可核算解释，不能称其在所有指标上领先。当前为单随机种子的代表配置比较，未给出多种子方差或统计显著性。




图 5.3 三分类混淆矩阵，行是真值、列是预测。中性与正向之间的混淆较突出。

表 5.5 验证集逐类别性能

验证类别	Precision	Recall	F1	支持数
负向	0.7401	0.6359	0.6841	206
中性	0.4524	0.5163	0.4822	184
正向	0.7273	0.7337	0.7305	338




图 5.4 验证集最终强度散点与残差分布。预测中性置零，形成 $\hat{y}=0$ 的水平带。

5.4.5 原生结构对照与性能取舍

在开源基线之外，补充原生骨干上“有序分类头”和“不确定性融合”两个模块的四格对照。四种设置均采用种子 17、最多 20 轮、早停耐心 4 轮，以及相同的 BERT 学习率、其他层学习率、模态丢弃率和联合监督基础权重；各自按验证 Macro-F1 选择轮次和决策策略。有序分类头指可学习的累计阈值输出，与四种设置均保留的强度有序辅助损失不同。

表 5.6 原生骨干的四种结构设置在验证集上的对照

结构设置	有序头	不确定性	轮次	Acc(%)	Macro-F1	MAE
联合监督基础	关	关	11	65.25	0.6412	0.5578
仅有序分类头	开	关	1	63.46	0.6230	0.5706
有序头+不确定性	开	开	3	63.74	0.6165	0.5688
不确定性融合(主)	关	开	5	65.11	0.6323	0.5397

仅加入有序分类头时，验证 Macro-F1 为 0.6230、MAE 为 0.5706；同时加入有序头与不确定性时，相应为 0.6165 和 0.5688，均弱于本文主模型的 0.6323 和 0.5397。对应的既有冻结测试结果中，两种有序设置的准确率均为 66.02%，Macro-F1 分别为 0.6342 和 0.6212，MAE 分别为 0.6210 和 0.6184，也未优于主模型。由此可见，更强的输出约束或更多融合模块并不自动带来更好的分类与回归表现。

联合监督基础设置在验证集的 Macro-F1 为 0.6412，高于主模型；主模型的 MAE 则降低约 0.0181。因此，四格对照支持不同结构之间存在性能取舍，不能据其

中两个较弱设置宣称不确定性模块对所有指标均有增益。各设置使用各自验证最优策略，比较包含训练与策略选择的共同影响；单种子结果也不构成稳定提升的证据。

5.4.6 学习率成组对照与较弱配置分析

5.4.7 验证集错误归因

验证集 728 条中分类错误 254 条。真实中性的 184 条中，89 条被判为非中性 (23 条负向、66 条正向)，中性召回率 51.63%；真实正向 338 条中 67 条被判中性，真实负向 206 条中 48 条被判中性。中性与正向混淆构成主要误差来源。中性边界校准改善取舍，仍不能解决说明性文本、弱情感与标注差异；继续扩大偏置会同时改变正负样本被归零的比例。

表 5.7 验证集标签与观测分组的误差

验证分组	样本数	分类错误数	错误率	最终 MAE
真实负向	206	75	36.41%	0.7233
真实中性	184	89	48.37%	0.2580
真实正向	338	90	26.63%	0.5811
视觉无有效观测	15	6	40.00%	0.4789
视觉存在有效观测	713	248	34.78%	0.5410

分组差异同时受标签分布、语句内容和观测质量影响，只能作为错误诊断线索，不构成模态缺失的因果效应。分类贡献在文本上的集中说明模型更依赖语言判别；语音与视觉的较低分类净贡献也可能来自内部正负项抵消，不能视为它们没有可用信息。强度预测的收缩与中性归零会对强情感样本产生较大残差，图5.4可用于检查这种系统偏差。

5.4.8 解释完备性检验

表 5.8 分类间隔与回归预激活的分解误差

解释检查	验证	测试	附件 4
分类间隔最大核算误差	1.52e-06	1.52e-06	5.29e-07
回归 q 最大核算误差	1.53e-07	1.53e-07	3.35e-08
逐样本核查数量	728	727	20

将三模态净分数与偏置相加，并与同次前向的目标分数逐条比较。1475 条样本的分解误差均处于浮点计算误差范围。该检查说明解释忠实于当前读出的数值，不证明某个证据词是人类情感成因。本主模型没有单独完成随机扰动对照、多种子解释稳定性或人类证据标注评价，局部读出核算与输入扰动忠实性仍需分别检验。

5.5 三模态作用差异与局部重要性

5.5.1 分类、回归与可靠性的区别

表 5.9 三模态净贡献占比的样本均值

集合/解释目标	文本 (%)	语音 (%)	视觉 (%)
验证集/分类间隔	84.76	6.88	8.36
验证集/回归 q	68.16	15.98	15.86
附件二测试集/分类间隔	84.62	6.71	8.68
附件二测试集/回归 q	71.14	13.58	15.28

上述比例先在每条样本内归一化，再对样本等权平均。验证与测试的分类文本占比均约 85%，而回归文本占比约 68%—71%，语音和视觉对强度的作用相对更高。附件 4 分类主要参考模态为文本 20/20，回归主要模态为文本 18/20、视觉 2/20 (02、14)；02 与 14 的视觉回归净贡献占比分别为 48.12% 与 41.09%。因此“分类主要看文本”不能推导出“强度估计中的视觉无作用”。




图 5.5 分类贡献、回归贡献与可靠性权重的对照。三者解释不同对象，不能互换。

附件 4 平均可靠性权重 T/A/V 为 45.07%/28.80%/26.12%，分类净贡献却为 89.78%/4.71%/5.51%。这来自不同模态证据大小、方向和抵消程度的共同影响，表明直接把可靠性权重写成贡献会失真。附件 4 的 13 号视觉数组全部为零，视觉单项和交互关闭，其视觉贡献应为 0；验证和测试分别有 15、28 条视觉无有效数值观测。

5.5.2 主要参考模态内的局部证据分布

局部重要性按分类间隔的有符号读出绘制。为避免只呈现支持结论的片段，图中保留每个有效位置及其正负方向：蓝色为支持预测类，红色为反对预测类。横轴采用原始分数量纲，纵轴保留原 BERT 位置与原文词元；这使典型解释可以回查到输入，而不只给出无位置的模态占比。




图 5.6 附件 4 样本 16 的主要参考模态内局部重要性。每行给出原 BERT 位置 and 对应原文，负值表示反对当前类别间隔；词的上下文由 BERT 编码。

5.6 附件四全量预测与典型解释

5.6.1 全量预测与三模态作用程度

附件四按题目中的无标签专项集处理。表中给出全部 20 条样本的预测极性、最终强度、分类间隔的三模态净贡献占比及分类、回归主要参考模态。比例均由同次前向的有符号净分数取绝对值后归一化；少量行因四舍五入可能不恰好合计 100%。

表 5.10 附件四 20 条样本的预测与分类贡献汇总

编号	预测极性	最终强度	文本 (%)	语音 (%)	视觉 (%)	分类/回归主模态
01	中性	+0.0000	96.43	3.50	0.06	T/T
02	正向	+1.0e-06	74.42	22.81	2.76	T/V
03	负向	-0.6588	98.46	0.41	1.13	T/T
04	负向	-0.4144	98.67	0.31	1.02	T/T
05	正向	+0.7983	81.97	3.64	14.38	T/T
06	正向	+0.9139	93.60	3.66	2.74	T/T
07	正向	+0.8535	90.50	2.19	7.31	T/T
08	正向	+0.5174	98.47	0.46	1.07	T/T
09	负向	-2.2932	99.50	0.19	0.31	T/T
10	负向	-2.1598	99.37	0.63	0.01	T/T
11	负向	-1.7402	99.40	0.52	0.08	T/T
12	负向	-0.6896	96.60	2.59	0.81	T/T
13	中性	+0.0000	93.27	6.73	0.00	T/T
14	中性	+0.0000	80.66	4.35	14.99	T/V
15	正向	+0.6387	73.61	15.05	11.34	T/T
16	负向	-2.6363	99.04	0.01	0.95	T/T
17	正向	+1.7645	94.11	1.66	4.23	T/T
18	负向	-0.5241	93.28	0.09	6.63	T/T
19	正向	+0.6309	71.34	8.08	20.58	T/T
20	正向	+0.5035	62.90	17.33	19.77	T/T

模型预测的类别分布为负向 8 条、中性 3 条、正向 9 条。该分布是预测输出的统计。样本 02 的最终强度为 $+1.0 \times 10^{-6}$ ，来自类别一致性处理，故以科学计数法保留其正号，避免将其显示为中性 0。

5.6.2 关键证据定位与结果文件

对每条样本，按局部贡献绝对值选取关键项，保留原特征索引、有符号分数及原文字符区间。20 条样本的原文、BERT 编号与字符映射均与原始输入逐项核对，原视频通过文件摘要确认。沿用问题一的独立语音识别与局部声学交叉支持规则，对附件四重新定位。完整音轨先由 Whisper 识别，识别过程只输入音频；原文随后与识别结果进行唯一词序匹配，每段至少含两个不同的信息锚点。对候选段分别扩展 0.5 秒和 1 秒上下文，用 MFA 进行局部强制对齐。

词级候选以扩展 0.5 秒上下文的声学边界为基准，分别与扩展 1 秒上下文的结果、独立识别的结果比较，两组最大端点差异均须不超过 0.2 秒，同时满足原词顺序和区间相容性。内部词界支持不足而外边界一致时，从 2—8 词候选中选择词序与时间均不重叠、覆盖未确定词最多的短语范围；其余位置保留原文本与贡献，标记语音定位支持不足。标点和连接符保留各自读出，不分配邻词的语音时间。0.2 秒为固定一致性门槛，不是实测定位误差。

附件四共 481 个规范化原词，得到 185 个词级候选，另有 44 个短语覆盖 123 个词级未确定词。三模态共 177 个关键读出中，61 项获得词级候选，43 项获得短语回看范围，63 项语音定位支持不足，10 项为标点或符号。其中 18 条样本具有可回看的关键项，另 2 条保留原文和贡献索引。此处按读出项统计，同一原词可以被不同模态引用；覆盖率与模型一致性分别描述可回查程度和候选支持，定位准确率需要独立时间真值。

63 项支持不足的关键读出中，14 项未形成唯一精确的文字匹配，10 项缺少足够

的连续片段锚点，39 项未通过局部声学边界检查。精确匹配会受专名、缩略语与识别差异影响；扩展上下文也可能带入候选段之外的语音，使局部强制对齐移动边界。因此，支持不足表示本组定位规则尚未给出充分依据，不能据此断言原词未发音或输入模态缺失。

对已定位关键项，从原视频实际帧时间戳中选取落在回看区间内、最接近区间中点的帧，记录帧序号、时间及图像摘要；重复帧合并保存。截图展示该时段的同步场景，图中人物与发声者的身份对应仍需单独验证。附件中的音视特征缺少原始采样时间，新定位用于媒体导航；模型贡献的归属继续由原特征索引确定。

候选范围以“词”和“组”分别表示词级候选及词组范围；帧时间由实际 PTS 记录。

表 5.11 附件四 20 条样本的主要证据定位索引

编号	主模态关键位置 / 原词元	有符号贡献	候选范围 (s)	同期帧 (s)
01	[7] / the	+0.1881	词 2.61—2.66	2.633
02	[17] / s	-0.1465	词 2.20—2.43	2.300
03	[14] / just	+0.1889	词 2.69—2.90	2.800
04	[24] / Absolutely	+0.2844	支持不足	—
05	[7] / ,	+0.3215	标点/符号	—
06	[33] / solely	+0.1871	组 6.71—7.33	7.033
07	[21] / enthusiastically	+0.1252	支持不足	—
08	[8] / Universal	+0.4617	支持不足	—
09	[18] / it	+0.5707	支持不足	—
10	[30] / terrible	+0.3731	支持不足	—
11	[4] / ashamed	+0.5581	组 0.87—3.34	2.100
12	[41] / low	+0.1494	支持不足	—
13	[19] / a	+0.1115	支持不足	—
14	[11] / Vet	+0.1775	支持不足	—
15	[20] / transform	+0.3343	支持不足	—
16	[5] / terrible	+0.9867	组 0.76—1.60	1.167
17	[14] / will	+0.3360	组 3.04—6.90	4.967
18	[17] / Meanwhile	+0.1514	支持不足	—
19	[3] / surprisingly	+0.1747	组 0.83—2.99	1.900
20	[36] / at	+0.0975	支持不足	—

运行 `run.py predict --model uncertainty --input 输入目录 --split special --output 输出目录 --device cpu`，加载固定模型生成预测与解释。媒体定位沿用问题一的识别和双上下文对齐配置，并按实际帧 PTS 提取同期画面。完整预测与解释以 CSV 汇总：一行对应一个样本，含类别、最终及原始强度、分类与回归净分数及比例、主要模态、三模态关键证据和可用状态。全部 20 条详细解释卡与该表使用同一批固定预测记录生成。

进一步将文本内容支持、特征可用性和媒体定位分别检查。附件四两套版本的原文与文本输入一致，视频逐条字节一致；13 号样本在对齐版中视觉数组全零，未对齐版仍有 17 行非零视觉特征。本文按所选对齐版关闭其视觉贡献，该状态表示当前输入无有效视觉观测。

15 号的完整音轨约 7.314 秒。Whisper 与 Wav2Vec2 CTC 分别在不输入原文的情况下识别音轨，均主要识别出所给句子之前的内容，在末尾才衔接到当前句开头，提示配套媒体可能存在剪辑边界偏移。该样本保留基于给定特征的预测与贡献，媒体对应标为待确认，解释卡不赋予缺少支持的语音区间。两个识别模型的一致现象用于异常筛查，不作为人工真值或故意篡改的判断。

5.6.3 典型样本解释卡

选取 02、13、16 号样本，分别展示分类与回归的主要模态差异、视觉缺失，以及文本主导的负向判断。分类贡献保留符号，回归贡献分解预激活 q 。序列位置均为原始零基 BERT 索引。

表 5.12 典型样本预测与模态贡献

项目	02	13	16
极性	正向	中性	负向
最终强度	0.000001	0.000000	-2.636344
原始强度	-0.0347	+0.1131	-2.6363
分类净分数 T	+0.4064	+1.8412	+10.6589
分类净分数 A	-0.1246	-0.1328	+0.0014
分类净分数 V	-0.0151	+0.0000	-0.1020
分类占比 T(%)	74.42	93.27	99.04
分类占比 A(%)	22.81	6.73	0.01
分类占比 V(%)	2.76	0.00	0.95
回归占比 T(%)	30.04	63.07	99.06
回归占比 A(%)	21.84	36.93	0.94
回归占比 V(%)	48.12	0.00	0.00
分类/回归主模态	T/V	T/T	T/T
分类间隔	0.7204	1.2547	10.9566
偏置	+0.4537	-0.4537	+0.3983

02 号原文为 “We want to live by each other’s happiness - not by each other’s misery.”。文本位置 [17] 的 s 读出为 -0.1465，候选区间 2.20—2.43 秒；[4] 的 live 读出 +0.1288，候选 0.78—0.94 秒；[18] 的 misery 为 -0.1352，语音定位支持不足。音频位置 [18] 贡献 -0.0120，视觉位置 [16] 贡献 -0.0014，均反对当前分类间隔。其分类主要参考文本，回归主要参考视觉；原始强度与分类分歧，经一致性处理后成为接近零的正值。



图 5.7 样本 02 的同期场景，实际帧时间 2.300 秒，落在文本位置 17 对应的候选区间内。

13 号原文讨论从数据中找出因素间关系。文本位置 [19] 的 *a* 贡献 +0.1115、语音定位支持不足；[21] 的 *between* 贡献 +0.1050，短语范围 5.03—6.48 秒。音频位置 [22] 的 *any* 贡献 -0.0107，对应同一短语范围。对齐版视觉输入全零，视觉项及相关交互关闭，模型以文本和音频输出中性。视频可供观看与所选视觉特征可用于模型是两个不同状态。

16 号原文为 “It’s a terrible, this is a terrible movie”。文本位置 [15] 和 [10] 的 *terrible* 分别贡献 +0.9867 与 +0.9827，前者位于 0.76—1.60 秒短语范围，后者获得 1.72—2.14 秒词级候选；位置 [13] 的 *s* 贡献 +0.9829，定位支持不足。音频位置 [17] 贡献 +0.0080，视觉位置 [17] 贡献 -0.0160，均回看 0.76—1.60 秒范围。文本净贡献占 99.04%，主导当前负向分类间隔。



图 5.8 样本 16 的同期场景，实际帧时间 1.167 秒。对应候选短语范围 0.76—1.60 秒。

6 模型评价与结论

本文围绕实际观测组织、局部缺失预测与决策解释，给出三项任务的模型、求解过程和全量结果。

问题一将原生特征、实际时间支持与文本候选分层保存。双上下文声学互证与词序、时间双顺序优化，在保持原始 100 条样本的同时，将词级或词组级候选覆盖提高至 1468/1932。逐维有效时长聚合处理局部无定义特征，词组范围保留连读弱读条件下的整体支持。受控扰动、声学量校核与重建实验分别验证稳定性、数值定义与实现一致性。

问题二的观测感知输入和类别平衡模型，在验证集三种子实验中提高 Macro-F1 与中性类 F1，伴随 Accuracy 及正向类 F1 下降。连续缺失增强的现有未加权对照未取得性能收益；缺失规律表现为文本更敏感，并随位置与片段形状改变。附件三 30 条预测保留分类和回归各自的实际输出。

问题三通过可加局部项、成对交互和可靠性缩放，将预测与内部解释统一。主模型验证 MAE 为 0.5397，Macro-F1 为 0.6323，反映回归误差与分类性能之间的取舍。附件四 20 条结果包含模态净贡献、主要模态和局部证据，已定位项关联原始媒体范围。贡献是当前前向计算的分解，媒体截图展示同期场景。

各项结论对应明确的评价对象：时间结果报告候选可用性，预测结果对应实际开发划分，解释结果对应模型读出。未确定文字位置保留原文与观测；视觉缺失关闭相关模型项；语音定位支持不足保留原特征索引与贡献值。由此使完整结果、输入状态与解释范围保持一致。

参考文献

- [1] Sanh V, Debut L, Chaumond J, et al. DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. 2019.
<https://arxiv.org/abs/1910.01108>
- [2] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition. CVPR, 2016. <https://arxiv.org/abs/1512.03385>
- [3] Google. MediaPipe Face Landmarker: Python guide. https://ai.google.dev/edge/mediapipe/solutions/vision/face_landmarker/python
- [4] Baevski A, Zhou Y, Mohamed A, et al. wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations. NeurIPS, 2020.
<https://arxiv.org/abs/2006.11477>
- [5] Radford A, Kim J W, Xu T, et al. Robust Speech Recognition via Large-Scale Weak Supervision. ICML, 2023.
<https://proceedings.mlr.press/v202/radford23a.html>
- [6] McAuliffe M, Socolof M, Mihuc S, et al. Montreal Forced Aligner: Trainable Text-Speech Alignment Using Kaldi. Interspeech, 2017: 498–502. https://www.isca-archive.org/interspeech_2017/mcauliffe17_interspeech.html
- [7] Devlin J, Chang M W, Lee K, Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]. NAACL-HLT, 2019: 4171–4186. DOI: 10.18653/v1/N19-1423.
<https://aclanthology.org/N19-1423/>
- [8] Google. bert-base-uncased model card[EB/OL].
<https://huggingface.co/google-bert/bert-base-uncased> 使用本地固定快照 86b5e0934494bd15c9632b12f734a8a67f723594, Apache-2.0 许可, 访问核验日期 2026-09-24。
- [9] scikit-learn developers. compute_class_weight, scikit-learn 1.7.2 documentation[EB/OL]. https://scikit-learn.org/1.7/modules/generated/sklearn.utils.class_weight.compute_class_weight.html, 访问日期 2026-09-25。
- [10] PyTorch contributors. CrossEntropyLoss, PyTorch 2.8 documentation[EB/OL]. <https://docs.pytorch.org/docs/2.8/generated/torch.nn.CrossEntropyLoss.html>, 访问日期 2026-09-25。
- [11] Loshchilov I, Hutter F. Decoupled Weight Decay Regularization[C]. ICLR, 2019. <https://arxiv.org/abs/1711.05101>
- [12] Agarwal R, Melnick L, Frosst N, et al. Neural Additive Models: Interpretable Machine Learning with Neural Nets. NeurIPS, 2021, 34: 4699–4711. <https://arxiv.org/abs/2004.13912>
- [13] Lou Y, Caruana R, Gehrke J, Hooker G. Accurate Intelligible Models with Pairwise Interactions. KDD, 2013: 623–631.
<https://doi.org/10.1145/2487575.2487579>

- [14] Kendall A, Gal Y. What Uncertainties Do We Need in Bayesian Deep Learning for Computer Vision? NeurIPS, 2017, 30.
<https://arxiv.org/abs/1703.04977>
- [15] Yu W, Xu H, Yuan Z, Wu J. Learning Modality-Specific Representations with Self-Supervised Multi-Task Learning for Multimodal Sentiment Analysis. AAAI, 2021, 35(12): 10790-10797.
<https://arxiv.org/abs/2102.04830>
- [16] Wang D, Guo X, Tian Y, Liu J, He L, Luo X. TETFN: A Text Enhanced Transformer Fusion Network for Multimodal Sentiment Analysis. Pattern Recognition, 2023, 136: 109259.
<https://doi.org/10.1016/j.patcog.2022.109259>
- [17] thuiar. MMSA: Multimodal Sentiment Analysis Toolkit[EB/OL].
<https://github.com/thuiar/MMSA>, 访问日期: 2026-09-26. 本文采用固定源码版本 a94e65d 的比赛适配实现。